

WiFi-Motion-Sensing

Exported on 2023-09-25 12:21:11

Inhalt

1	Untersuchung von Helbling-Daten	4
1.1	Beschreibung der verfügbaren Daten	4
1.1.1	Verfügbare Daten	4
1.1.2	Übersicht über die aufgezeichneten Daten pro Durchlauf	5
1.1.3	Beobachtungen	7
1.2	Data exploration	7
1.2.1	Beispiel für den Verlauf der CSI-Amplitude und Verteilung von statistischen Kenngrößen	8
1.2.2	Analysen im Frequenz-Spektrum mittels der Fast-Fourier-Transformation	10
1.2.3	Korrelationen zwischen den Klassen-Labels und den statistischen Features, bzw. dem Frequenz-Spektrum	12
1.3	Automated Feature selection	15
1.3.1	Model independent tuning	15
1.3.2	Gradient Boosting	16
1.4	Klassifikations-Ergebnisse	17
1.4.1	Support Vector Classification (SVC)-Modell	17
1.4.2	XGBoost-Modell	24
2	DASU Versuchsreihen	27
2.1	Anpassung der Aufnahmen-Konfiguration	27
2.2	Versuchsbeschreibung	29
2.2.1	Versuchsreihe Distanz	29
2.2.2	Versuchsreihe Erkennung von Bewegung zum Receiver	30
2.2.3	Allgemeine Anmerkungen	31
2.2.4	Zu untersuchende Einflussfaktoren	31
2.2.5	Weitere mögliche Störfaktoren	32
2.2.6	Zu erfassende Kenngrößen für alle Versuchsreihen	32
2.2.7	Vorbereitungen Hardware	32
2.3	Versuchsplanung für Sprint 4	33
2.3.1	Distanz-Versuchsreihe	33
2.3.2	2. Leeres Büro über langen Zeitraum	36
2.3.3	3. Küchen-Versuchsreihe (nicht für Sprint 4 geplant)	36
2.4	Beschreibung der Aufzeichnung und des Labelings	37
2.5	Distanz-Versuche	37
2.5.1	Äußere Begebenheiten	37
2.5.2	Versuchs-Aufbau und -Ablauf	38
2.5.3	Visualisierung und Evaluation der Durchläufe	41
2.5.4	Inkonsistente Sampling-Rate	45
2.5.5	Ergebnisse Anwesenheits- und Bewegungserkennung	48
2.5.6	Diskussion	52
2.6	Küchen-Versuche	53
2.6.1	Hintergrund	53
2.6.2	Fragestellungen	53
2.6.3	Äußere Begebenheiten	53
2.6.4	Versuchs-Aufbau und -Ablauf	54
2.6.5	Beschreiben des Labeling-Prozesses	60
2.6.6	Visualisierung und Evaluation der Durchläufe	61
2.6.7	Ergebnisse Anwesenheits- und Bewegungserkennung	72
2.6.8	Diskussion	76
3	Einfluss- / Störfaktoren auf das WiFi-, bzw. CSI-Signal	77
3.1	Frequenzband und Kanal der Übertragung zwischen Transmitter und Receiver	77
3.2	Netzwerkaktivität im gleichen und in umliegenden Netzwerken	78
3.3	Positionierung von Transmitter und Receiver	78
3.4	Räumliche Begebenheiten	79
3.5	Andere Elektrogeräte	81
3.6	Bewegungen und Aktivität außerhalb des betrachteten Bereichs	81
3.7	Luftfeuchtigkeit	82
3.8	Konfiguration bei Programmstart	82
4	Literatur-Liste	83
5	Hürden, Einschränkungen und Next Steps	85
5.1	Zeitliche Verzögerungen zwischen Signal-Eingang und Prädiktion	85


5.2	Kurze Dauer der Bewegung von Interesse	86
5.3	Unidentifizierte Einflussgrößen.....	86
5.4	Next Steps	86

1 Untersuchung von Helbling-Daten

1.1 Beschreibung der verfügbaren Daten

Auf dieser Seite wird die Struktur der verfügbaren Daten für das “WiFi-motion sensing” Projekt beschrieben und es werden Beispiele für den Verlauf der aufgezeichneten CSI-Amplituden und -Phasen gezeigt.

1.1.1 Verfügbare Daten




- **preliminary measurements:**
 - 4 Testläufe, in welchen eine Tasse nahe dem Receiver bewegt wurde.
- **freezer measurements:**
 - 3 verschiedene Personen (WJU, GVA, CAM) wurden jeweils angewiesen, 200 Durchläufe der vier Szenarien “Nobody in the room” (**NIR**), “Someone walking toward the receiver” (**WTR**), “Someone walking in the room” (**WIR**) or “Someone standing in the room” (**SIR**) durchzuführen. Das jeweilige Szenario wurde für jeden Durchlauf zufällig ausgewählt.
- **kids measurements:**
 - Von 3 unterschiedlich großen Kindern (small, medium, big) und einer erwachsenen Frau wurden 200 mal je eine Person ausgewählt, um sich entweder im Raum zu bewegen, dort zu stehen oder den Raum leer zurück zu lassen.


1.1.2 Übersicht über die aufgezeichneten Daten pro Durchlauf

Pro Durchlauf wurde über eine Zeitspanne von ca. 5 Sekunden die Channel State Information (CSI) eines Signals aufgenommen, welches 52 Subcarrier umfasst. Die CSI ist ein komplexer Wert, welcher in eine **Amplitude** und eine **Phase** aufgeteilt werden kann. Beispiele für den Verlauf dieser beiden Parameter während dem Ausführen der vier Szenarien NIR, SIR, WIR, WTR werden in den folgenden Bildern gezeigt. Zusätzlich zu der CSI wurden außerdem Videos der Durchläufe aufgezeichnet. Diese werden ebenfalls gezeigt:


Example run of "Nobody in the room" (amplitude)




Example run of "Nobody in the room" (phase)




Example run of "Someone walking toward the receiver" (amplitude)




Example run of "Someone walking toward the receiver" (phase)




Example run of "Someone standing in the room" (amplitude)




Example run of "Someone standing in the room" (phase)



Example run of "Someone walking in the room" (amplitude)



Example run of "Someone walking in the room" (phase)



1.1.3 Beobachtungen

- In den Beispielen kann man klare Unterschiede in den CSI-Amplituden erkennen zwischen den Klassen, in denen keine Bewegung stattfindet (NIR, SIR) und denen mit Bewegung (WIR, WTR). Letztere zeigen viel größere Schwankungen. In der Phase kann man auf den ersten Blick kein eindeutiges Muster erkennen, das die vier Klassen voneinander trennt. Aufgrund dessen wurde entschieden, in den folgenden Untersuchungen das Hauptaugenmerk auf die CSI-Amplitude zu richten.
- Betrachtet man das Video zur Klasse SIR, kann man sehen, dass für diese Klasse eine Person aufgezeichnet wurde, die über mehrere Sekunden komplett starr im Raum steht. In einem der Absprachetermine zwischen DASU und BSH, kamen wir zu dem Entschluss, dass das kein sehr realistisches Szenario sei, aus dem sich praktische Use-Cases ableiten lassen. Deshalb wird diesem Szenario in den weiteren Untersuchungen weniger Beachtung geschenkt als den restlichen.

1.2 Data exploration

Diese Seite zeigt die Ergebnisse der Datenexploration. Ich wollte eine Pipeline erstellen, in der ich zunächst einige Unterscheidungsmerkmale in einem Datensatz finde und dann diese Merkmale als Eingabe für ein Klassifizierungsmodell verwende. Ich wollte sehen, ob die Daten einer einzelnen Person bereits ausreichen, um diese Pipeline zu erstellen und ein Modell zu trainieren, das auch auf die Daten anderer Personen anwendbar ist. Daher wurde die Datenexploration in einem ersten Schritt nur mit den Daten des Probanden WJU durchgeführt.

Die Ergebnisse dieses Abschnitts wurden BSH in der ersten Sitzung nach dem Kickoff vorgestellt.

1.2.1 Beispiel für den Verlauf der CSI-Amplitude und Verteilung von statistischen Kenngrößen

Um die Unterschiede herauszustellen, die in der CSI-Amplitude zwischen den verschiedenen Klassen bestehen, werden im Folgenden die Amplituden-Verläufe eines einzelnen Subcarriers während einzelner Durchläufe gezeigt. Die ausgesuchten Beispiele repräsentieren die auffälligsten Muster, die die Klassen unterscheiden, sehr gut.

In Fig. 1.1 wird für jede der Klassen “Nobody in the room” (**NIR**), “Someone walking toward the receiver” (**WTR**), “Someone walking in the room” (**WIR**) or “Someone standing in the room” (**SIR**) ein Beispiel für die CSI-Amplitude des Subcarriers 48 gezeigt. Zusätzlich wird der Durchschnittswert der Amplitude während des jeweiligen Durchlaufs als gestrichelte Linie gezeigt.



Fig.1.1: Beispiele für den Verlauf der CSI-amplitude des Subcarriers 48 für vier verschiedene Klassen mit der durchschnittlichen Amplitude während des Durchlaufs (gestrichelte Linie).

Eine erste Beobachtung ist, dass in den “No Movement”-Klassen (NIR & SIR) ein niedrigerer Durchschnittswert gehalten wird, als in den “Movement”-Klassen (WIR & WTR). Außerdem treten in den “Movement”-Klassen deutlich stärkere Schwankungen auf. Aufgrund dessen kann es lohnenswert sein, zu betrachten, wie die typischen statistischen Merkmale “Durchschnitt” und “Standardabweichung” (STD) der Durchläufe aus den verschiedenen Klassen jeweils verteilt sind. Dafür wurden diese Werte für jeden der Durchläufe für den Subcarrier 48 berechnet und die Ergebnisse werden in Box-Plots in Fig. 1.2 dargestellt:




Fig.1.2(a): Mean amplitudes for the all courses of the different classes.




Fig.1.2(b): Amplitude standard deviation for all courses of the different classes.

Der Subcarrier 48 wurde für die Darstellungen ausgesucht, da sich die Muster, welche hier beschrieben werden, für diesen am deutlichsten bemerkbar machen. Dennoch konnten die Muster auf ähnliche Weise auch für alle anderen Subcarrier beobachtet werden, wenn auch weniger deutlich ausgeprägt.

Die folgenden Beobachtungen können gemacht werden:

1. Wir sehen, dass die STD der Klassen NIR und SIR ungefähr im gleichen Bereich liegen, abgesehen von einigen Ausreißern in der Klasse SIR.
2. Die STD'en der "Movement"-Klassen WIR & WTR sind deutlich größer als die der "No Movement"-Klassen (NIR & SIR).
3. Die Klasse SIR zeigt die höchste Varianz in den Durchschnittswerten der Amplitude. Die Werte neigen dazu, höher als die der Klasse NIR zu liegen. Diese Beobachtung ist in vielen anderen Subcarriern deutlich weniger ausgeprägt. Dort sehen sich die Verteilungen der durchschnittlichen Amplituden für die beiden Klassen NIR und SIR deutlich ähnlicher.
4. Die Durchschnitts-Amplituden der Klassen WIR & WTR liegen ebenfalls höher als die der Klasse NIR. Diese Beobachtung findet sich in fast allen anderen Subcarriern ebenfalls wieder.

1.2.2 Analysen im Frequenz-Spektrum mittels der Fast-Fourier-Transformation

Eine weitere Möglichkeit, um Effekte in Zeitreihen zu entdecken, ist die Betrachtung der jeweiligen Frequenz-Spektren. Dafür wird die Methode "Fast-Fourier-Transformation" (FFT) auf die Zeitreihe angewandt. Die erhaltenen Absolutwerte enthalten Informationen darüber, wie stark Schwankungen bestimmter Frequenzen in der jeweiligen Zeitreihe vertreten sind.

Für die vorhandenen Daten, liegt keine einheitliche Sampling-Rate vor, was jedoch Voraussetzung für die FFT ist. Daher wurde vor der Anwendung der FFT zunächst eine lineare Interpolation auf die Amplituden aller Subcarrier und aller Durchläufe angewandt. Anschließend wurde außerdem von allen Amplituden aller Subcarrier die durchschnittliche Amplitude aus dem jeweiligen Durchlauf abgezogen. Dies wurde gemacht, um die "Direct Current" (DC)-Komponente aus den Daten zu entfernen, welche extrem große Werte für die Frequenz von 0Hz verursacht bei Daten, die nicht um den Wert 0 zentriert sind. Anschließend wurde das Hamming-Window auf die Daten der jeweiligen Durchläufe angewandt, was eine Standard-Prozedur ist für die Anwendung der FFT. Auf die durch das Hamming-Window transformierten Daten wurde letztendlich die FFT angewandt.

Diese Prozedur wurde für die Darstellungen in Fig. 1.3 auf die Daten des Subcarriers 48 angewandt. Das Frequenz-Spektrum zeigt nur Frequenzen <20Hz, da nur in diesem Bereich Unterschiede zwischen den verschiedenen Klassen beobachtet werden konnten.

Subträger: 48




Fig. 1.3: Frequenz-Spektrum aller Amplituden-Zeitreihen von Subcarrier 48.

Hier können wieder verschiedene Beobachtungen gemacht werden:

1. Im Frequenz-Bereich $<15\text{Hz}$ zeigen die Klassen WIR & WTR zumeist eine höhere Power als NIR & SIR.
2. Auf den ersten Blick gibt es kein offensichtliches Muster, das die Klassen WIR & WTR trennt. Die Power der sehr niedrigen Frequenzen $<1\text{Hz}$ tendieren bei WTR dazu, etwas höher zu sein, als bei WIR.
3. Abgesehen vom Bereich $<1\text{Hz}$ gibt es kaum Unterschiede zwischen NIR & SIR.
4. Die Vergrößerung des Bereichs $<1\text{Hz}$ in den Klassen NIR & SIR (hier nicht gezeigt) zeigt, dass die meisten SIR-Durchläufe dort eine ähnliche Power wie die NIR-Durchläufe aufweisen, abgesehen von einigen Ausreißern.
- 5.

1.2.2.1 Untersuchung der Ausreißer in der Klasse SIR

Wie vorhin erwähnt, konnten einige Ausreißer im Frequenzspektrum der Klasse SIR ausgemacht werden, die erneut in Fig. 1.4 gezeigt werden. Diese hatten eine höhere Power in dem Bereich von 1Hz bis 7Hz als die anderen Reihen der selben Klasse.




Fig. 1.4: Ausreißer im Frequenz-Spektrum Der Klasse SIR

Die Videos dieser Ausreißer werden in Fig. 1.5 (b)-(d) gezeigt. Dort kann man sehen, dass die Versuchsperson (VP) WJU nicht komplett still steht, sondern einen Schritt nach vorne oder zur Seite macht. Zum Vergleich wird in Fig. 1.5 (a) ein normaler Ablauf dieser Klasse gezeigt, in der sich die VP, abgesehen von einer Kopfbewegung, nicht bewegt.

Das deutet darauf hin, dass der Frequenzbereich zwischen 1Hz und 10Hz ein guter Indikator für die Erkennung von Bewegung sein kann.

Im Austausch mit BSH wurde besprochen, dass eine Bewegungsdetektion als Supplement für die reine Anwesenheitserkennung dienen kann, da Abschnitte, in den Personen still im Raum stehen zwangsläufig mit vorherigen oder darauf folgenden Bewegungen einher kommt. Deswegen wurde entschieden, dass die korrekte Erkennung der Klasse SIR nicht weiter im Fokus stehe.

1.2.3 Korrelationen zwischen den Klassen-Labels und den statistischen Features, bzw. dem Frequenz-Spektrum

Bisher wurden die Features, die wir zur Unterscheidung der verschiedenen Klassen verwenden wollen, nur heuristisch betrachtet. Außerdem wurden sie nur beispielhaft für den einzelnen Subcarrier 48 gezeigt. In diesem Abschnitt werden nun allgemein gültige Ergebnisse präsentiert, welche das Potential verschiedener Features zur Unterscheidung der Klassen quantifizieren.

Die Größen, die im vorherigen Abschnitt beschrieben wurden (Amplituden-Durchschnitt, -Standardabweichung, Power im Frequenzspektrum), wurden hierfür für alle verfügbaren Subcarrier berechnet. Den Durchläufen wurden Labels der zugehörigen Klasse zugeordnet und der Korrelationskoeffizient R^2 jeder Klassen-Paarung wurde berechnet. Dieser gibt den Grad an, zu dem sich die Verteilungen eines Features zweier verschiedener Klassen unterscheiden. Ein hoher Wert (nahe 1) deutet darauf hin, dass die betrachteten Klassen für diese Feature stark unterschiedlich verteilt sind und dadurch unterschieden werden können. Ein kleiner Wert (nahe 0) deutet darauf hin, dass es für die beiden Klassen in diesem Feature kaum Unterschiede in der Verteilung gibt.

Die Ergebnisse für alle Klassen-Paarungen und für alle Subcarrier können in Fig. 1.6 gesehen werden:




Fig. 1.6(a): R^2 -Korrelation zwischen verschiedenen Klassen-Paarungen für Amplituden-Durchschnittswerte




Fig. 1.6(b): R^2 -Korrelation zwischen verschiedenen Klassen-Paarungen für Amplituden-Standardabweichung

Die wichtigsten Beobachtungen hier sind die Folgenden:

1. Besonders hohe Korrelationskoeffizienten (bis zu 0.8) finden sich für die Paarungen "NIRvsWTR" und "NIRvsWIR" für alle Subcarrier in beiden Größen. Interessant ist hier, dass die Korrelation bei den Durchschnittswerten für manche Subcarrier nahe dem Index 48 höher ist, als bei den restlichen.
2. Relativ hohe Korrelationskoeffizienten (ca. 0.4) werden für die Klassen "NIRvsSIR" erreicht, jedoch nur in einigen Subcarriern nahe dem Index 48.
3. Die höchsten Korrelationskoeffizienten bei "WTRvsWIR" treten in einer anderen Teilmenge der Subcarrier auf als bei den anderen Paarungen, nämlich nahe dem Subcarrier 26.

Aus den hohen Korrelationskoeffizienten können wir bereits schließen, dass die Betrachtung der simplen statistischen Features der CSI in den kurzen Zeitabschnitten nützlich für die Klassifikations-Aufgabe sein kann.

Die R^2 -Korrelationskoeffizienten wurden ebenfalls für alle Subcarrier für die Power-Werte des Frequenz-Spektrums berechnet und werden in Fig. 1.7 dargestellt. Für Fig. 1.7(a) wurden die Klassen WIR und WTR zur Klasse “Bewegung” und die Klassen NIR und SIR zur Klasse “Keine Bewegung” zusammengefasst. Dadurch sollte untersucht werden, wie die Features damit korrelieren, ob Bewegung stattfindet oder nicht.




Fig. 1.7(a): R^2 values in the frequency spectrum for classes “Movement” (WIR + WTR) vs “No Movement” (NIR + SIR)




Fig. 1.7(b): R^2 values in the frequency spectrum for classes NIR vs SIR

'Someone walking in the room' vs 'Someone walking toward the receiver'




Fig. 1.7(c): R^2 values in the frequency spectrum for classes WIR vs WTR

Die wichtigsten Beobachtungen sind:

1. Der komplette Frequenz-Bereich $<20\text{Hz}$ zeigt hohe R^2 -Werte (bis zu 0.6) für die Unterscheidung zwischen den Klassen "Bewegung" und "Keine Bewegung".
2. Für den Vergleich "NIRvsSIR" (Fig. 1.7(b)) bestehen keine signifikant großen R^2 -Werte ($R^2 < 0.2$).
3. Für "WIRvsWTR" (Fig. 1.7(c)) wird die stärkste Korrelation im Frequenzbereich $<2\text{Hz}$ erreicht. Außerdem bestehen noch relativ hohe Korrelationskoeffizienten in einem zweiten Bereich ($[11\text{Hz}, 19\text{Hz}]$).

Es ist wichtig zu erwähnen, dass diese Beobachtungen bisher nur aufgrund der Daten der Person WJU aufgestellt wurden. Es ist wahrscheinlich, dass die Verteilungen der betrachteten Werte bei den Daten der anderen Personen unterschiedlich aussehen. Dennoch sollten die Beobachtungen zumindest zu einem Teil übertragbar sein.

1.3 Automated Feature selection

The output of the Fast Fourier Transform (FFT) seemed to be very promising to contain features which are suitable to perform the classification task on them. Manually selecting some features from that space delivered some promising results already but they still could be optimized. In this section I describe how I researched on a method which takes the whole output of the FFT, which results in a very big number of features, as input and automatically scales the importance of features or of combinations of features. By that the complete data is used for the training of a classification model.

1.3.1 Model independent tuning

First I want to highlight two aspects which can be adapted to a desired outcome which is not a specific model parameter. It still can be adapted for the training of basically all classification methods.

- "Sample weights":
 - Specifies how much each sample from the training data contributes to the loss function of the classifier.
 - E.g., by assigning larger weights to those samples from class WTR the model is influenced in such a way that it will make less false negative decisions for that class but at the same time more false positives.

- In our case, I gave more weight to class WTR and achieved a precision of >90% for that class while the precision for class WIR was only at ~65%. ~20% of WIR were falsely classified as WTR.
- “Decision threshold”:
 - Most classification methods (for multi-class classification) calculate for each sample probabilities to belong to either one of the desired classes. By default, they chose the class with the highest probability for the predicted class.
 - If it is more important to correctly classify one class than another one, this decision rule can be adapted. E.g., one could say that one class always is chosen as soon as it's probability is >33%, even though the probability for another class might be at 45%. Verbally, this would mean “If we are 33% sure that this sample belongs to class WTR, we choose class WTR”.

1.3.2 Gradient Boosting

1.3.2.1 Most important parameters

- `max_features / colsample_bynode`:
 - None, “sqrt”, “log2” or fraction of `n_features`.
 - In each step when the optimal split is searched only a subset of all features is presented. By that the algorithm is forced to use multiple different features to create good splits and can not only focus on single features which would be prone to over-fitting.
 - When None is used, all features are used in every step. “sqrt” takes the square-root of the number of features. “log2” takes the log to the basis 2 of the number of features. “log2” results in a smaller number than “sqrt” (for a large number of input features).
 - Using sqrt or log2 rather than None makes the model much more robust. Also the training is done much faster.
- `max_depth`:
 - Determines the depth of each tree which is part of the Gradient Boosting Algorithm and thus, limits the number of leafs for each tree.
 - Has to be chosen depending on the interaction of the input features. In our case, I suppose, it should be chosen not too small because the decision making should be based on a combination of at least a couple of different points in the frequency spectrum of several sub-carriers.
 - A too large number might lead to overfitting. With a too low number many potentially important features could be disregarded. This can happen especially when the parameter “max_features” is chosen as “sqrt” or “log2”, because only a randomly chosen subset of all features is presented for the training of the trees and
 - Should be determined by hyper-parameter-tuning.
- `n_estimators`:
 - Determines the maximal number of trees / stages which are built for the Gradient Boosting Algorithm.
 - Increasing can improve the performance of a model. A too high number still does not affect the over-fitting too badly.
 - When using early-stopping, the number of estimators may be cut off at a smaller number, since the usage of more estimators does not bring an improvement any more on a validation set.

- subsample:
 - Determines the fraction of the training data which is randomly chosen and presented to each stage of the Boosting Algorithm.
 - By not presenting the complete training dataset in each step the model does not learn to focus too much on single outliers and thus, get's more robust.
 - Optimal value should be found by hyper-parameter-tuning. 0.8 seems to be a good starting point.
- reg_alpha, reg_lambda:
 - L1- / L2-regularization terms which regularize the leaf weights. Discourages individual trees from making strong predictions.
 - Needs to be chosen carefully to prevent lying too much weight to the regularization terms. Optimal value should be searched by hyper-parameter-tuning.
- early_stopping_rounds:
 - Number of iterations after which no new stages are created if an evaluation metric (e.g. accuracy) is not improved any more on a validation set.
 - Prevents over-fitting by preventing to improve the training-error while the validation-error stays unchanged after some iterations.
 - I would recommend using this parameter.
- learning_rate:
 - Determines the rate at which the weights of the stages decline.
 - I did not have a look at this parameter yet.
 - Should be optimized by hyper-parameter-tuning.

1.4 Klassifikations-Ergebnisse

1.4.1 Support Vector Classification (SVC)-Modell

In einem ersten Versuch herauszufinden, wie gut sich die statistischen Features und die Features aus dem Frequenzspektrum, welche in [Data exploration \(deutsch\)](#) beschrieben wurden, eignen, um die Klassifikationsaufgabe zu lösen, wurde ein (sehr simples) Support Vector Classification (SVC)-Modell aufgestellt.

Im Kapitel [Data exploration \(deutsch\)](#) konnten wir sehen, dass besonders die Fälle "Bewegung" (WIR+WTR) und "keine Bewegung" (NIR+SIR) stark unterschiedliche Features aufwiesen. Das führte zur Vermutung, dass die Klassifizierung dieser beiden Fälle zuverlässig funktionieren kann. Innerhalb dieser übergeordneten Kategorien waren war zu sehen, dass weniger klare Unterschiede zu sehen, die geeignet sind, um letztendlich die Klassen WIR und WTR, bzw. NIR und SIR, voneinander zu unterscheiden. Außerdem spielten unterschiedliche Features eine Rolle für die Unterscheidung der Klassen WIR und WTR, bzw. NIR und SIR. Deswegen wurde entschieden, in einem ersten Schritt ein hierarchisches Modell, welches in einem ersten Schritt erkennen soll, ob in einem Durchlauf Bewegung stattfand oder nicht und basierend darauf erst in einem zweiten Schritt die tatsächliche Klasse bestimmen sollte. Die Struktur ist zu sehen in Fig. 1.8:




Fig. 1.8: Struktur des hierarchischen Modells.

Das gesamte hierarchische Modell kombiniert drei kleinere binäre SVC-Modelle. Für jedes davon wurden lediglich 3 Features ausgesucht, welche die höchsten R^2 -Werte im vorherigen Kapitel für die jeweilige Unterscheidung aufwiesen. Die Modelle sollten lernen, anhand dieser jeweils 3 Features die jeweilige Unterscheidung ausführen zu können.

Das Modell wurde auf verschiedene Arten trainiert und evaluiert.

1.4.1.1 Training und Evaluation auf nur Daten von WJU

In der ersten Variante wurden nur die Durchläufe der Person WJU verwendet. Diese wurden während einer 5-fold Cross-Validation mehrmals in Trainings- und Test-Datensätze aufgeteilt. Für jeden der Cross-Validation-Durchläufe wurde die erreichte Accuracy für die beiden Stufen des Modells berechnet. Für Stufe 1 des Modells, also die Bewegungserkennung, wurde eine durchschnittliche Accuracy von 94% erreicht, für Stufe 2, also die Bestimmung des genauen Labels, eine Accuracy von 81%. Die Ergebnisse werden in Fig. 1.9 in Confusion-Matrizen dargestellt. Dort wird gezeigt, wie viele Durchläufe, mit einem bestimmten "True label", (x-Achse) welchem "Predicted label" vom Modell zugewiesen wurden.




Fig. 1.9(a): Confusion matrix für Level 1 Ergebnisse.




Fig. 1.9(b): Confusion matrix für Level 2 Ergebnisse.

Man kann sehen, dass die reine Bewegungserkennung sehr zuverlässig funktioniert. Auch die Klassen WIR und WTR können sehr gut voneinander unterschieden werden. Lediglich bei der Klasse SIR wird ca. die Hälfte der Fälle fälschlicherweise der Klasse NIR zugewiesen.

1.4.1.2 Training auf Daten von WJU, Evaluation auf Daten von CAM

In einem zweiten Szenario sollte überprüft werden, ob die Daten, die von einer Person erhoben wurden, ausreichen, um ein Modell zu trainieren, das anschließend in der Lage ist auch die Daten, die von einer anderen Person stammen, zu klassifizieren. Dafür wurde ein Modell auf den selben Features wie zuvor mit den Daten der Person WJU trainiert. Anschließend wurde evaluiert, wie die Klassifikation der Daten von Person CAM funktionierte. Die Ergebnisse können in Fig. 1.10 betrachtet werden.




Fig. 1.10(a): Confusion matrix für Level 1 Ergebnisse.




Fig. 1.10(b): Confusion matrix für Level 2 Ergebnisse.

Wir können sehen, dass auf diese Weise immer noch eine hervorragende Accuracy von 96% für die reine Bewegungserkennung erreicht wird. Lediglich bei der Bestimmung der tatsächlichen Klassen scheitert das Modell offensichtlich. Auf den Daten der Person CAM wird in den Fällen ohne Bewegung fast ausschließlich für die Klasse SIR entschieden, auch bei den Fällen, die eigentlich aus der Klasse NIR stammen. Bei den Durchläufen mit Bewegung wurde überwiegend für die Klasse WIR entschieden. Auf der zweiten Ebene wurde dadurch nur eine Accuracy von 42% erreicht.

1.4.1.3 Weitere Settings

Für das weitere Vorgehen wurde entschieden, lediglich die drei Klassen NIR, WIR & WTR zu berücksichtigen. Aufgrund dessen wurde das

Es wurden noch weitere Kombinationen für Trainings- und Test-Daten getestet. Die Zusammenstellungen der Trainings- und Testdaten sowie die erreichten Ergebnisse auf den Test-Daten werden in der folgenden Tabelle berichtet. Die Labels wurden für die Tabelle umbenannt und die neuen Labels entsprechen den alten folgendermaßen: 1=NIR, 2=WIR, 3=WTR.

In den unten stehenden Confusion-Matrizen wird außerdem nicht mehr in absoluten Zahlen berichtet, welche Fälle mit einem "True label" welchem das "Predicted label" zugeordnet wurden, sondern der Prozentsatz der Fälle mit einem "True label", welchem das "Predicted label" zugeordnet wird.

Personen für Trainingsdaten	Personen für Testdaten	Confusion-Matrix																
WJU	CAM	Train.: WJU, Pred.: CAM & CAM Test accuracy: 0.67 <table><tr><th>True label \ Predicted label</th><th>0</th><th>1</th><th>2</th></tr><tr><th>0</th><td>1</td><td>0</td><td>0</td></tr><tr><th>1</th><td>0.047</td><td>0.77</td><td>0.19</td></tr><tr><th>2</th><td>0.02</td><td>0.76</td><td>0.22</td></tr></table>	True label \ Predicted label	0	1	2	0	1	0	0	1	0.047	0.77	0.19	2	0.02	0.76	0.22
True label \ Predicted label	0	1	2															
0	1	0	0															
1	0.047	0.77	0.19															
2	0.02	0.76	0.22															
WJU, CAM	GVA	Train.: WJU & CAM, Pred.: GVA Test accuracy: 0.43 <table><tr><th>True label \ Predicted label</th><th>0</th><th>1</th><th>2</th></tr><tr><th>0</th><td>1</td><td>0</td><td>0</td></tr><tr><th>1</th><td>0.83</td><td>0.17</td><td>0</td></tr><tr><th>2</th><td>0.94</td><td>0.059</td><td>0</td></tr></table>	True label \ Predicted label	0	1	2	0	1	0	0	1	0.83	0.17	0	2	0.94	0.059	0
True label \ Predicted label	0	1	2															
0	1	0	0															
1	0.83	0.17	0															
2	0.94	0.059	0															
GVA	WJU, CAM	Train.: GVA, Pred.: WJU & CAM Test accuracy: 0.51 <table><tr><th>True label \ Predicted label</th><th>0</th><th>1</th><th>2</th></tr><tr><th>0</th><td>0.65</td><td>0.34</td><td>0.0096</td></tr><tr><th>1</th><td>0</td><td>0.96</td><td>0.043</td></tr><tr><th>2</th><td>0</td><td>0.99</td><td>0.0092</td></tr></table>	True label \ Predicted label	0	1	2	0	0.65	0.34	0.0096	1	0	0.96	0.043	2	0	0.99	0.0092
True label \ Predicted label	0	1	2															
0	0.65	0.34	0.0096															
1	0	0.96	0.043															
2	0	0.99	0.0092															
75% der Daten von WJU, CAM, GVA	25% der Daten von WJU, CAM, GVA	Train-test-split all adults Test accuracy: 0.72 <table><tr><th>True label \ Predicted label</th><th>NIR</th><th>WIR</th><th>WTR</th></tr><tr><th>NIR</th><td>0.96</td><td>0.041</td><td>0</td></tr><tr><th>WIR</th><td>0.13</td><td>0.64</td><td>0.23</td></tr><tr><th>WTR</th><td>0.16</td><td>0.38</td><td>0.47</td></tr></table>	True label \ Predicted label	NIR	WIR	WTR	NIR	0.96	0.041	0	WIR	0.13	0.64	0.23	WTR	0.16	0.38	0.47
True label \ Predicted label	NIR	WIR	WTR															
NIR	0.96	0.041	0															
WIR	0.13	0.64	0.23															
WTR	0.16	0.38	0.47															

Hier kann man erneut sehen, dass beim Transfer von WJU auf CAM gut unterschieden wird, ob sich die Person bewegt oder nicht, auch wenn die Unterscheidung zwischen WIR & WTR nicht gut funktioniert.

Beim Transfer von den Personen WJU & CAM auf die Person GVA wurden die schlechtesten Ergebnisse erzielt. Hier entschied das Modell trotz dem Training auf den Daten zweier Personen in beinahe jedem Fall für die Klasse NIR, also dafür dass sich niemand im Raum befinde.

Drehte man das Szenario um und nutzte die Daten der Person GVA zum Training und evaluierte auf WJU & CAM, so ergab sich ein besseres Bild, bei dem in 100% der Fälle, in denen sich eine Person bewegt, das auch erkannt wurde. Allerdings wird auch in 34% der Fälle

der Klasse NIR stattdessen für die Klasse WIR entschieden.

Für das letzte Setting wurden die Daten aller 3 Erwachsenen zu einem großen Datensatz kombiniert und dann zufällig in einen Trainings- und einen Testdatensatz aufgeteilt. Diese enthielten 75% und 25% der gesamten Daten. Wurde das SVC-Modell auf diesen Daten trainiert und evaluiert, so ergab sich insgesamt ein gutes Bild für die Bewegungserkennung. Besonders die Trennung der Klassen mit und ohne Bewegung funktionierte sehr zuverlässig. Nur 13% und 16% der Fälle in den Klassen WIR & WTR wurden der Klasse NIR zugeteilt. Andersherum wurden nur 4% der NIR-Fälle der Klasse WIR zugeordnet. Die Unterscheidung der Klassen WIR & WTR fällt dem Modell weiterhin schwer. Jedoch wird in diesem Setting für beide Klassen deutlich häufiger korrekt als falsch entschieden.

Da für die hier erzeugten Ergebnisse mit dem SVC nur ein sehr einfaches Modell verwendet wurde, dem zudem nur wenige, händisch ausgewählte Features übergeben wurden, lassen die Erkenntnisse hoffen, dass mit einem umfangreicheren Modell, das automatisiert aus allen verfügbaren Features die ausschlaggebenden selektieren kann, noch zuverlässigere Ergebnisse erreicht werden können.


1.4.2 XGBoost-Modell

Für ein solches Modell wurde die Methode eXtreme Gradient Boosting, kurz "XGBoost", gewählt. Dieses Modell ist eine Ensemble-Methode, bei der mehrere Entscheidungsbäume trainiert werden, deren Entscheidungen zu einer gemeinsamen Entscheidung kombiniert wird. Die Bäume werden im Trainingsprozess so angepasst, dass sie jeweils die Fehler, die von anderen Bäumen gemacht werden, möglichst beheben. Das Modell hat die besondere Eigenschaft, dass es besonders robust gegenüber Overfitting ist. Selbst bei wenigen Trainingsdaten und der Anwesenheit vieler Input-Features können im Trainingsprozess wenige ausschlaggebende Features identifiziert werden und zur Klassifikation genutzt werden. Sind viele Features präsent, die stark miteinander korreliert sind, so werden wenige Repräsentanten ausgewählt. Der Trainings-Methode in Python beinhaltet viele Hyper-Parameter, die für eine bessere Regularisierung und für eine bessere Performance angepasst werden können. Die wichtigsten Hyper-Parameter werden im Kapitel [Automated Feature selection](#) erläutert. Für ein schnelleres Vorgehen bei den Untersuchungen wurden die Hyper-Parameter händisch so angepasst, dass sie möglichst gute Ergebnisse ergaben. Für noch weiter optimierte Ergebnisse sollte eine automatisierte Hyper-Parameter-Suche ausgeführt werden, was z.B. durch das Python-Package "Optuna" möglich ist. Dieses Vorgehen ist allerdings sehr zeitintensiv, weswegen es für die hier angestellten Untersuchungen nicht berücksichtigt wurde.


Eine weitere Anpassung, die für den Trainingsprozess gemacht werden kann, ist die Zuteilung von Gewichten für ausgewählte Trainings-Daten. So kann zum Beispiel bestimmt werden, dass den Samples der Klasse WTR ein größeres Gewicht zuteil wird, wodurch Fehler, bei denen Samples dieser Klasse falsch klassifiziert werden, im Trainingsprozess schwerer wiegen und eher vermieden werden. Das Modell entscheidet letztendlich mit einer höheren Wahrscheinlichkeit, dass ein Sample zu dieser Klasse gehört. Dadurch werden einerseits mehr Samples der Klasse WTR korrekt erkannt, andererseits werden auch mehr Samples der übrigen Klassen fälschlicherweise dieser Klasse zugeordnet. Je nach Use-Case kann so zu einem gewissen Grad gesteuert werden, welche Klasse eher korrekt erkannt werden soll, bzw. welche Fehler eher vermieden werden sollen oder in Kauf genommen werden können.

Für die folgenden Ergebnisse wurden mehrere xgboost-Modelle mit den selben Hyper-Parametern, aber mit unterschiedlichen Gewichtungen für die drei vorhandenen Klassen, trainiert. Als Input-Features wurde der komplette Output aus der Prozedur der FFT übergeben. Das resultierte in einer sehr großen Anzahl an Input-Features, die sogar deutlich größer war als die Anzahl der Trainings-Samples. Dennoch war die Methode in der Lage, Overfitting zu vermeiden und auf den jeweiligen Test-Daten gute Performance zu zeigen.


In den folgenden Darstellungen werden die Ergebnisse des xgboost-Modells gezeigt, bei denen jeweils unterschiedliche Klassen-Gewichtungen festgelegt wurden. Die Gewichtung erfolgte jeweils proportional zum Anteil der jeweiligen Klassen im Trainings-Datensatz. Man kann sehen, dass hier für die Bewegungserkennung genauso gute Ergebnisse erzielt werden wie zuvor. Jedoch findet eine wesentlich bessere Unterscheidung der Klassen WIR und WTR statt.




class	precision	recall	f1-score	support
NIR	0.88	1	0.93	35
WIR	0.84	0.69	0.76	39
WTR	0.85	0.89	0.87	46
weighted avg	0.86	0.86	0.85	120




class	precision	recall	f1-score	support
NIR	0.88	1	0.93	43
WIR	0.82	0.71	0.76	38
WTR	0.87	0.85	0.86	39
weighted avg	0.86	0.86	0.85	120



class	precision	recall	f1-score	support
NIR	0.97	0.83	0.89	46
WIR	0.62	0.91	0.74	33
WTR	0.94	0.76	0.84	41
weighted avg	0.87	0.82	0.83	120



class	precision	recall	f1-score	support
NIR	0.92	1	0.96	45
WIR	0.74	0.57	0.64	30
WTR	0.81	0.87	0.84	45
weighted avg	0.83	0.84	0.83	120



class	precision	recall	f1-score	support
NIR	0.92	0.96	0.94	47
WIR	0.9	0.46	0.61	39
WTR	0.65	0.97	0.78	34
weighted avg	0.84	0.8	0.79	120

2 DASU Versuchsreihen

2.1 Anpassung der Aufnahmen-Konfiguration

Um eigene Experimente innerhalb der DASU-Räumlichkeiten durchzuführen, musste die Konfiguration des Aufnahme-Setups angepasst werden. Die Änderungen sollen hier beschrieben werden.

Auf dem Aufnahme-Laptop befindet sich der Unterordner "data_aquisition/data_acquisition/". In diesem liegen die Methoden vor, um neue Aufnahmen zu starten. Im "Readme", welches auf dem Desktop des Rechners liegt, wird beschrieben, wie neue Aufnahmen gestartet werden können.

Aufnahmen können nur aus einer Linux-Umgebung heraus gestartet werden.

In dem Unterordner befindet sich eine "config"-Datei, die angepasst werden muss, bevor neue Aufnahmen gemacht werden.

Zunächst wird in der Datei die Variable "video_device" definiert. Hier wird der Pfad zum Gerät spezifiziert, welches für die Video-Aufnahme verwendet wird. Das Gerät "/dev/video0" steht immer für die im Laptop integrierte Kamera. Ist eine externe Kamera über USB angeschlossen kann über den Befehl

"ffplay /dev/video[Nummer der Kamera]"

der Output des Geräts betrachtet werden und überprüft werden, ob das richtige Gerät ausgewählt ist:



```
config - Editor
Datei Bearbeiten Format Ansicht Hilfe
[parameter]
record_video_command = /usr/bin/ffmpeg -loglevel panic -t $duration -f v4l2 -input_format mjpeg -i $device -r 10 -s 320x240 -f mp4
record_csi_command = python3 -m data_acquisition.read_serial --serial_device $device --timeout $duration

standard_duration = 5

experiment_path = /var/lib/experiments

wifi_scan_interface = wlan0
video_device = /dev/video0
serial_device = /dev/ttyUSB0
baud_rate = 1552000

scenario = ["freezer.json", "kid.json", "count.json"]
chip = "ESP32-S2-Saola-1R"
access_point = "ESP32-S2-Saola-1R"

csi_suffix = -csi.csv
metadata_suffix = -metadata.json
video_suffix = -video.mp4
wifi_suffix = -wifi.json

[logs]
level = INFO
format = %(asctime)s %(levelname)s - %(name)s - %(message)s
```

Ist die richtige Kamera ausgewählt, muss als nächstes in der Config-Datei die Variable "record_video_command" angepasst werden. In dem dort spezifizierten Befehl muss das Argument "-input_format" an die ausgewählte Kamera angepasst werden. Über den Befehl "ffmpeg -f v4l2 -list_formats all -i /dev/video[Nummer der Kamera]" kann das richtige input_format des gewählten Kamera ausgelesen und in den Befehl der Config-Datei eingetragen werden:

```
config - Editor
Datei Bearbeiten Format Ansicht Hilfe
[parameter]
record_video_command = /usr/bin/ffmpeg -loglevel panic -t $duration -f v4l2 -input_format mjpeg -i $device -r 10 -s 320x240 -f mp4
record_csi_command = python3 -m data_acquisition.read_serial --serial_device $device --timeout $duration

standard_duration = 5

experiment_path = /var/lib/experiments

wifi_scan_interface = wlp3s0
video_device = /dev/video0
serial_device = /dev/ttyUSB0
baud_rate = 1552000

scenario = ["freezer.json", "kid.json", "count.json"]
chip = "ESP32-S2-Saola-1R"
access_point = "ESP32-S2-Saola-1R"

csi_suffix = -csi.csv
metadata_suffix = -metadata.json
video_suffix = -video.mp4
wifi_suffix = -wifi.json

[logs]
level = INFO
format = %(asctime)s %(levelname)s - %(name)s - %(message)s
```

Des weiteren muss die Variable “standard_duration” angepasst werden. Dort wird spezifiziert, wie lang in Sekunden die neue Aufnahme dauern soll:

```
config - Editor
Datei Bearbeiten Format Ansicht Hilfe
[parameter]
record_video_command = /usr/bin/ffmpeg -loglevel panic -t $duration -f v4l2 -input_format mjpeg -i $device -r 10 -s 320x240 -f mp4
record_csi_command = python3 -m data_acquisition.read_serial --serial_device $device --timeout $duration

standard_duration = 5

experiment_path = /var/lib/experiments

wifi_scan_interface = wlp3s0
video_device = /dev/video0
serial_device = /dev/ttyUSB0
baud_rate = 1552000

scenario = ["freezer.json", "kid.json", "count.json"]
chip = "ESP32-S2-Saola-1R"
access_point = "ESP32-S2-Saola-1R"

csi_suffix = -csi.csv
metadata_suffix = -metadata.json
video_suffix = -video.mp4
wifi_suffix = -wifi.json

[logs]
level = INFO
format = %(asctime)s %(levelname)s - %(name)s - %(message)s
```

Außerdem muss die Liste “scenario”, um die Dateinamen der Szenarien erweitert werden, die die neuen Aufnahmen spezifizieren:

```
config - Editor
Datei Bearbeiten Format Ansicht Hilfe
[parameter]
record_video_command = /usr/bin/ffmpeg -loglevel panic -t $duration -f v4l2 -input_format mjpeg -i $device -r 10 -s 320x240 -f mp4
record_csi_command = python3 -m data_acquisition.read_serial --serial_device $device --timeout $duration

standard_duration = 5

experiment_path = /var/lib/experiments

wifi_scan_interface = wlp3s0
video_device = /dev/video0
serial_device = /dev/ttyUSB0
baud_rate = 1552000

scenario = ["freezer.json", "kid.json", "count.json"]
chip = "ESP32-S2-Saola-1R"
access_point = "ESP32-S2-Saola-1R"

csi_suffix = -csi.csv
metadata_suffix = -metadata.json
video_suffix = -video.mp4
wifi_suffix = -wifi.json

[logs]
level = INFO
format = %(asctime)s %(levelname)s - %(name)s - %(message)s
```

Im Unterordner “/data_aquisition/data_acquisition/scenarios/” finden sich die .json-Dateien, in denen die möglichen Aktionen spezifiziert werden, die im jeweiligen Szenario durchgeführt werden sollen. Falls ein neues Szenario erstellt werden soll, muss hier eine neue Datei erstellt werden. Die Dateien sind ähnlich aufgebaut, wie ein python-dictionary. Die Klassennamen werden dort aufgelistet:

```
{
  "0": "Klasse 1",
  "1": "Klasse 2",
  ...
}
```

2.2 Versuchsbeschreibung

Hier wird die Planung verschiedener Versuchsreihen geplant, die innerhalb des (alten) DASU-Bürogebäudes ausgeführt werden können.

2.2.1 Versuchsreihe Distanz

Wurde letztendlich so ausgeführt.

2.2.1.1 Hintergrund

Wenn in einem festen Setting zuverlässig erkannt werden kann, dass sich eine Person z.B. in einem Radius von 2m von einem Gerät entfernt befindet, kann eine gewünschte Aktion getriggert werden.

2.2.1.2 Fragestellungen

- Kann für einzelne Personen anhand des CSI-Signals festgestellt werden, in welcher Entfernung zu Transmitter und Receiver sie sich bewegen?
- Kann ich Unterschiede in den Signalen erkennen in Abhängigkeit zur Distanz zwischen Person und Transmitter / Receiver?
- Wie sehen diese Unterschiede aus?

2.2.1.3 Durchführung:

- Transmitter und Receiver werden mit bestimmtem Abstand (z.B. 10m) voneinander im Flur aufgestellt.
- Person(en) werden direkt zwischen Transmitter und Receiver gestellt, bleiben für mehrere Sekunden dort stehen und bewegen sich immer wieder in 1m / 2m Schritten in eine Richtung.

Oder

Personen laufen auf geraden / kreisförmigen Linien (möglichst gleich bleibender Abstand) zwischen Transmitter und Receiver hin und her.

- Es soll überprüft werden, ob es einen direkten Zusammenhang zwischen gewissen Kenngrößen, wie z.B. der durchschnittlichen Amplitude, und der Entfernung zu Tr. und Rec. gibt.
- Möglichst ohne Schwankungen anderer Einflussfaktoren (Tageszeit, Bewegungen in Nebenräumen, Geräte/Objekte im Raum, etc) durchführen um Distanz als einzigen Einflussfaktor zu isolieren.
- Es sollen Markierungen in Form von farbigem Klebeband auf dem Boden angebracht werden
 - In verschiedenen Abständen zu Receiver und Transmitter
 - Entweder senkrecht zur Verbindungslinie von Transmitter zu Receiver oder kreisförmig
- Farbliche Hervorhebung der Schuhe kann vorteilhaft sein, um relative Position zu Markierungen auf dem Boden möglichst präzise zu dokumentieren.

- Hier macht es Sinn, ähnlich wie bei den Aufnahmen von Helbling, mehrere kurze Aufnahmen mit einer fixen Länge von einigen Sekunden zu produzieren. Ansonsten wird der Aufwand unnötig groß, die jeweiligen Ausschnitte aus einer kontinuierlichen Aufnahme zu extrahieren.

2.2.2 Versuchsreihe Erkennung von Bewegung zum Receiver

Wegen dem eingeschränkten Zeitkontingent konnte diese Reihe letztendlich nicht ausgeführt werden. Die zu erwartenden Ergebnisse wären denen aus der Distanz-Versuchsreihe vermutlich sehr ähnlich gewesen.

2.2.2.1 Hintergrund

In einem realistischen Setting wird ein Signal durchgehend aufgezeichnet und ausgewertet. Es soll erkannt werden, wann ein bestimmtes Ereignis auftritt, auf das ggf. eine Reaktion folgt. Es soll möglich sein zwischen einem Ruhezustand, in dem sich niemand in einem Raum aufhält, irrelevanten Bewegungen, die keine Reaktion triggern sollen, und "Targeting"-Bewegungen, auf die eine Reaktion folgen würde, zu unterscheiden.

2.2.2.2 Fragestellungen

- Kann ein kontinuierliches Signal so ausgewertet werden, dass zuverlässig erkannt, zu welchen Zeitabschnitten eine Bewegung hin zum Receiver (Targeting) erkannt wird?
- Kann zuverlässig unterschieden werden, zwischen Abwesenheit von Personen, irrelevanten Bewegungen und Targeting?
- Die Daten wie vieler Personen müssen für einen Trainingsdatensatz zusammengefasst werden, damit ein darauf trainiertes Modell auch zuverlässige Ergebnisse liefert, wenn es auf noch unbekannte Personen angewandt wird?
- Optional: Kann zwischen verschiedenen Personen anhand des CSI-Signals unterschieden werden?
- Optional: Kann zwischen Personen und einem Hund unterschieden werden?

2.2.2.3 Durchführung

- Es sollen ähnliche Muster wie in den vorherigen Versuchen von Helbling betrachtet werden. Allerdings soll statt getrennten Aufnahmen von jeweils 5 Sekunden längere kontinuierliche Durchläufe aufgenommen werden, während denen Übergänge zwischen den verschiedenen Zuständen möglich sein. Durch Tags sollen Zeitstempel / Zeitabschnitte mit den jeweiligen Zuständen markiert werden.
- In den einzelnen Durchläufen sollen sich verschiedene Personen damit abwechseln, vordefinierte Aktionen durchzuführen.
 - Die einzelnen Aktionen sollten eine gewisse Variabilität aufweisen, damit sich ein ML-Modell nicht auf wenige fixe Muster versteift und leichte Abweichung davon schlecht erkennt. Z.B. bei Bewegungen hin auf den Receiver soll nicht immer der gleiche Weg gemacht werden, sondern aus verschiedenen Richtungen zugegangen werden.
- Es soll klar definiert und unterschieden werden, welche Bewegungen / (Zeit-)Abschnitte als "Target" (Walking toward the receiver/Inhalt WTR) gelabelt werden.
- Zwischen oder während den Aufnahmen sollen einige Begebenheiten im Raum verändert werden:
 - Objekte sollen aufgestellt oder verschoben werden.
 - Elektrogeräte, wie Handys sollen benutzt werden.

- Fenster und Türen sollen geöffnet und geschlossen werden.
- Dies soll alles dokumentiert werden mit jeweiliger Veränderung und Zeitpunkt.
- Zustände sollten reproduzierbar sein.
- Farbliche Markierungen auf dem Boden und an Versuchspersonen sollten auch hier angebracht werden.
 - Distanz soll hier nicht primär untersucht werden, kann aber nützlich zu sein, um klarer zu definieren, ob sich jemand auf den Receiver hin bewegt oder nicht.

2.2.3 Allgemeine Anmerkungen

- Vergleichbare Situationen (gleiche Personen, Handlungen, generelles Setup, etc.) zu unterschiedlichen Tageszeiten oder generell an unterschiedlichen Tagen sollen durchgeführt werden
 - Damit sollen mögliche zeitliche oder sonstige “zufällige” Schwankungen in den Signalen untersucht werden.
- Gewünschte Anzahl an verschiedenen Versuchspersonen: min. 6-8 (je mehr desto besser)
 - Damit soll untersucht werden, ob der Transfer von Modellen von Personen, die im Training bekannt sind, auf Personen, die nur für die Evaluation genutzt werden, möglich ist.
 - Außerdem soll möglichst dargestellt werden können, in welchem Maß die Generalisierung steigt, durch eine Steigerung der Anzahl an Personen im Trainingsdatensatz (Wie performt das Modell, wenn ich auf 2, 3, 4, ... Personen trainiere und auf anderen, bis dahin unbekannten Personen validiere?). Dafür soll eine gewisse Steigerung der Trainings-Personen möglich sein, während gleichzeitig genügend Test-Personen übrig bleiben.

2.2.4 Zu untersuchende Einflussfaktoren

- Offene Türen und Fenster
- Bewegungen im Nebenraum / Flur
- Objekte im Raum
 - Reflektierende Oberflächen besonders interessant
 - z.B. Gläser, Spiegel, Tische, Rollcontainer (einfach verstellbar), Stühle, Brotdosen (Metall reflektiert vielleicht), Kleidung
- Elektrogeräte im Raum / in der Nähe des Raums
 - z.B. Handys, Laptops, Bildschirme, Kopfhörer, Heizstrahler, Mikrowellen, Straßenbahnen, Herd
 - Anwesenheit von WiFi-fähigen Geräten
- Raumgröße
- Positionierung von Transmitter und Receiver in unterschiedlichen Räumen. In der Realität würden z.B. ein WLAN-Router als Transmitter und ein Kühlschrank als Receiver selten im gleichen Raum stehen.

2.2.5 Weitere mögliche Störfaktoren

Hier sollen noch weiter mögliche Störfaktoren aufgelistet werden, die in diesen Versuchsreihen nicht näher untersucht werden.

- Installation neuer Geräte, die im WLAN-Netz kommunizieren
 - z.B. Drucker, SmartTV's, smarte Lampen
- Vorbeifahrende Straßenbahnen emittieren relativ starke el.mag. Strahlung, die potentiell auch WiFi-Signale beeinflussen kann
- ...

2.2.6 Zu erfassende Kenngrößen für alle Versuchsreihen

- Größe beteiligter Personen
- Gewicht
- Namenskürzel
- Geschlecht
- Datum und Uhrzeit der Durchläufe
- Fotos von Raumsetup
- Ein Formular soll erstellt werden, in dem vor der Durchführung eines Experiments festgelegt wird, welche Veränderungen am und im Raum durchgeführt werden (Fenster / Türen öffnen, Mikrowelle benutzt, Objekte verschoben), welche Person(en) welche Aktionen ausführen sollen, wann Bewegung im Nebenraum stattfinden soll, etc.
- (Außentemperatur)
- ... ?

2.2.7 Vorbereitungen Hardware

- Positionierung von Transmitter und Receiver soll festgehalten werden (Fotos vom Raum ohne Personen).
- Transmitter und Receiver auf Rollcontainern.
 - Zusätzlich Erhöhung vorbereiten, um Positionierung auf möglichst realistischer Höhe zu gewährleisten.
- Kamera geschickt positionieren:
 - Möglichst hoch (mehr oder weniger top-down-Perspektive, wenn möglich)
 - Personen sollen vollständig aufgenommen werden
 - Aktivität und Position der Person(en) soll erkennbar sein, trotz eventuellem Blurring
 - Event. Markierungen auf Boden (z.B. für Distanz-Messungen) sollen erkennbar sein

- Halterung, um Kamera eventuell möglichst in einer hohen Ecke im Raum festzuhalten (vielleicht Halterung mit Saugnäpfen, um Kamera an Fenstern anzubringen)
- Markierungen für Positionierung im Raum vorbereiten
 - Farbiges, breites Klebeband
- Schuhe der Versuchspersonen sollen präpariert werden durch farbliche Markierung, die in Videos gut erkennbar ist. Dadurch soll erkennbar sein, in welcher Distanz sich die jeweilige Person zu Transmitter / Receiver befindet in Kombination mit Markierungen auf dem Boden. Die Farbe sollte sich gut vom Teppichboden abheben.
 - Z.B. gelbe Markierung ebenfalls mit Klebeband.
 - Neon-gelber "Klipser" um Fußgelenk.

2.3 Versuchsplanung für Sprint 4

2.3.1 Distanz-Versuchsreihe

2.3.1.1 Labels für Distanz-Versuchsreihe

- Eine Ebene für Namenskürzel, welches Versuchsperson (VP) im Segment etwas ausführt
- Eine Ebene, ob sich die VP bewegt, stillsteht, der Raum leer ist oder ob Versuch gestartet wird:
 - Start recording
 - Empty Room
 - Standing
 - Moving
- Eine Ebene, um die Distanz zum Receiver zu kennzeichnen (in 1m Abschnitten), also Distanz <1m, 1m<=...<2m, usw. (mit Klebeband markiert)
 - 0 m
 - 1 m
 - etc.
- Eine Ebene, in welchem Winkel zur Verbindungslinie zwischen Receiver und Access Point das Versuchsobjekt steht; 7 verschiedene Winkel, von -1m bis +1m (senkrecht zu RC - AAP)
 - -1,20m
 - -0,60m
 - 0m
 - 0,60m
 - 1,20m
- Eine Ebene, ob das Fenster geschlossen oder geöffnet ist

2.3.1.2 Genaue Durchführung einzelner Durchläufe

1. Aufnahme von (x) Minuten wird gestartet durch Versuchsleiter (VL)
2. VL startet die Stoppuhr und macht sie sichtbar für VP
3. VL verlässt den Raum und entfernt sich möglichst weit von der Türe
4. Raum wird für ca. 30sec leer aufgenommen

5. VP betritt Raum
6. VP bleibt direkt vor dem Receiver ruhig stehen für ca. 15sec
7. VP läuft direkt vor dem Receiver hin und her (90° Winkel zu Verbindungslinie zw. Rec. und AP) für ca. 15sec
8. VP läuft zu nächster Distanzmarkierung
9. VP läuft zu nächster Distanzmarkierung und wiederholt Schritte 2-4 bis bei der letzten Markierung gelaufen wurde
10. VP verlässt den Raum und entfernt sich möglichst weit von der Türe
11. leerer Raum wird für die restliche Zeit aufgenommen

Zeit-Management:

- Start der Aufnahme und verlassen des Raums von VL: ca. 30sec
- Aufnahme des leeren Raums: ca. 30sec
- Pro Routine bei Abstandsmarkierungen ca. 30sec; 5 Markierungen → 150sec
- Verlassen des Raums von VP: ca. 10sec
- Aufnahme des leeren Raums: ca. 40sec
- Insgesamt: 260sec → 4:20 min

Anzahl Durchläufe:

- Pro VP 4-5 Durchläufe → ca. 20-25 Minuten pro Person
- 5 verschiedene VP'en → insges. ca. 2,5 - 3 Stunden

Raumaufbau und Abläufe:




Fig. 2.1: Aufbau und Markierungen im Raum




Fig. 2.2: Verschiedene Abläufe: Reihenfolge, in der die Markierungen im Raum Abgelaufen werden sollen.

2.3.1.3 Checkliste

- Keine Handy's / sonst. internetfähigen Geräte
- Alle Fenster und Türen geschlossen
- Markierungen für Distanz vorhanden
- Markierungen für Winkel vorhanden
- Einweisung für VP wurde vorgenommen

2.3.2 2. Leeres Büro über langen Zeitraum

2.3.2.1 Genaue Durchführung

- Wenn alle Mitarbeiter (außer VL) das Büro verlassen haben, wird eine Aufnahme über einen langen Zeitraum von min. 30 Minuten gestartet.
- Der VL verlässt das Büro nach dem Start der Aufnahme und hinterlässt es komplett leer.

2.3.3 3. Küchen-Versuchsreihe (nicht für Sprint 4 geplant)

2.3.3.1 Labels für Küchen-Versuchsreihe

- Eine Ebene für Namenskürzel, welches Versuchsobjekt im Segment etwas ausführt
- Eine Ebene, um die Distanz zum Receiver zu kennzeichnen

- Raum in 3 Abschnitte aufteilen mit Markierungen:
 - Direkt davor
 - Relativ nahe
 - Weit entfernt
- Eine Ebene, ob sich jemand im selben Raum, wie der Receiver bewegt/aufhält oder im Nebenraum
- Eine Ebene, um zu kennzeichnen, ob sich jemand zufällig bewegt, gezielt auf den Receiver zu bewegt, stillsteht oder ob der Raum leer ist
- Ebene, ob Person Internet-fähiges Gerät benutzt hat

2.4 Beschreibung der Aufzeichnung und des Labelings

Hier soll zusammengefasst beschrieben werden, wie die Aufzeichnungen genau vonstatten gingen.

2.5 Distanz-Versuche

Auf dieser Seite soll beschrieben werden, wie die "Distanz"-Versuche durchgeführt wurden, und ihre Ergebnisse sollen beschrieben und diskutiert werden.

2.5.1 Äußere Begebenheiten

Zunächst soll in diesem Abschnitt beschrieben werden, in welchem Umfeld die Distanz-Versuche durchgeführt wurden.

- Für die Versuche wurde ein leerer Raum innerhalb unseres (alten) Büros vorbereitet. Zu dem Zeitpunkt stand das Gebäude, in dem wir uns befanden, leer, abgesehen von unserem Büro. Dementsprechend gab es in den Stockwerken über und unter dem Versuchsaufbau keine anwesenden Personen und Bewegungen und Anwesenheit von Menschen wurde nur von Personen aus unserem Büro beeinflusst.
- Das Büro befand sich im 3. Obergeschoss des Gebäudes. Demnach sollten auch Bewegungen und Anwesenheit außerhalb des Gebäudes wenig Einfluss auf die aufgenommenen Daten gehabt haben.
- In dem präparierten Raum befanden sich außer den Geräten und deren Aufbauten keine Möbel oder sonstigen Objekte.
- Der Raum grenzte auf einer Seite an den Flur mit einer Gips-Wand und einer Türe. Auf einer anderen Seite grenzte er ebenfalls mit einer Gips-Wand an einen Raum, in dem mehrere Tische gelagert wurden und in dem ein PC durchgehend lief. Gegenüber dazu grenzte der Raum an einen weiteren Raum, in dem hauptsächlich leere Kartonagen lagerten. Dazwischen befand sich eine ebenfalls eine Gips-Wand, die allerdings zu einem großen Teil von Fenstern und einer Türe, ebenfalls mit Fenster, ausgefüllt war. Auf der vierten Seite des Raums befand sich eine Fensterfront, die das Büro nach außen abgrenzte. Die Fenster wurden während den Versuchen geschlossen gehalten. (In Fig. 2.4 zu sehen)
- Die Versuche wurden an zwei verschiedenen Tagen, am 04.07.2023 und am 05.07.2023, und an den Tagen jeweils zu unterschiedlichen Uhrzeiten aufgenommen. Abhängig vom Zeitpunkt der Aufnahme befanden sich unterschiedlich viele Personen in den restlichen Räumen des Büros. (Korreliert mit der Anzahl der Personen variierte auch die Anzahl der Geräte, die mit einem nahen WiFi-Netzwerk kommunizierten.)

2.5.2 Versuchs-Aufbau und -Ablauf

Für die Versuche wurde ein leerer Raum innerhalb unseres (alten) Büros vorbereitet. Der Aufbau des Raums und seiner Nebenräume ist in der unteren Abbildung abgebildet. In diesem Raum wurde ein Transmitter / Access Point (AP) an einer Steckdose angeschlossen und mittig an der Wand, die zum Flur des Büros angrenzte, positioniert. Ein Receiver (RC) wurde direkt gegenüber vor einer Fensterfront, die das Büro nach außen abgrenzte, positioniert.

Im Raum wurden farbige Markierungen auf dem Boden angebracht, deren Positionen in Fig. 2.3 markiert sind. Für die Versuchsdurchläufe wurden verschiedene Pfade festgelegt, bei denen die Versuchspersonen (VPs) jeweils 5 der Markierungen besuchten und an ihnen jeweils 15 Sekunden lang still standen und sich dann 15 Sekunden lang in einem kleinen Radius um den jeweiligen Punkt hin- und her-bewegten, bis sie zum nächsten Punkt gingen.




Fig. 2.3: Aufbau und Markierungen der Distanz-Versuche mit aufgebautem Transmitter / Access Point (AP) und Receiver (RC) und Markierungen bestimmter Positionen im Raum



Fig. 2.4: Photo von Distanz-Versuchs-Aufbau

Für die Versuchsdurchläufe wurden verschiedene Pfade festgelegt, bei denen die Versuchspersonen (VPs) jeweils 5 der Markierungen besuchten und an dort jeweils eine kurze Routine ausführten. Die Abläufe waren:

- **A1:** 2 - 5 - 9 - 12 - 13
- **A2:** 5 - 7 - 9 - 11 - 12
- **A3:** 7 - 8 - 9 - 10 - 11
- **A4:** 1 - 4 - 5 - 6 - 3

15 Sekunden lang still standen und sich dann 15 Sekunden lang in einem kleinen Radius um den jeweiligen Punkt hin- und her-bewegten, bis sie zum nächsten Punkt gingen.

Für die einzelnen Versuchsdurchläufe sah der zeitlicher Ablauf folgendermaßen aus:

- Der Versuchsleiter (VL) startete die Aufnahme, verließ daraufhin den Versuchs-Raum und ging zu einem Punkt weit abseits des Versuchs-Raums.
- Es wurde bis 00:45 nach Aufnahmestart außerhalb gewartet, bis die VP los ging, um den Versuchs-Raum zu betreten, um eine Baseline-Aufnahme des leeren Raums zu machen.
- Spätestens bei 01:00 stand die VP an dem ersten Punkt des vorgegebenen Pfades und blieb dort bis 01:15 still stehen.

- Bei 01:15 fing die VP an, sich in einem kleinen Radius um den jeweiligen Punkt hin- und herzubewegen, bis sie schließlich bei 01:30 beim nächsten Punkt des Pfades stehen blieb.
- Diese 30 Sekunden lange Routine wurde an allen Punkten des Pfades wiederholt, bis die VP sich am letzten Punkt 15 Sekunden lang hin- und herbewegte.
- Nach der letzten Routine, bei 03:30 verließ die VP den Raum und entfernte sich davon.
- Der Raum wurde erneut für 30 Sekunden aufgenommen, in denen er leer war.

Insgesamt wurden 25 der oben beschriebenen Durchläufe durchgeführt und aufgenommen (In den ersten 4 Aufnahmen wurde jedoch der zeitliche Ablauf noch nicht genau so eingehalten wie oben beschrieben. Da deswegen die Zuordnung der verschiedenen Aktivitäten nicht präzise realisierbar war, werden diese im folgenden nicht visualisiert). Es nahmen 5 verschiedene Personen teil, die jeweils unterschiedlich viele Durchläufe machten. Insgesamt wurde der Ablauf A1 4 mal durchgeführt, A2 10 mal, A3 5 mal und A4 6 mal. Die Durchläufe fanden an 2 Tagen statt. Am 04.07.2023 wurden über den Tag hinweg verteilt 6 Aufnahmen gemacht, am 05.07.2023 die restlichen 19.

Die Rohdaten, die vom Aufnahme-Setup aufgezeichnet wurden, befinden sich in der Projektstruktur unter:

/wifimo/data/raw/04_DASU_Distanzen/

Für jeden aufgezeichneten Durchlauf wurde dort ein Unterordner angelegt, der die Rohdaten in einer CSV-Datei und eine unscharf gemachte Version des jeweils aufgenommenen Videos enthält in den Dateien:

.../{experiment_name}-csi.csv
und
.../{experiment_name}-blurred_video.mp4

Die aus den Rohdaten extrahierten Informationen über Zeitstempel, CSI-Amplitude & -Phase, Subcarrier-Zugehörigkeit, Versuchspersonen, Kategorie und Experimenten-Namen finden sich für jeden Durchlauf unter:

/wifimo/data/processed/08_DASU_kitchen/{experiment_name}_compact.csv

2.5.3 Visualisierung und Evaluation der Durchläufe

Die Ergebnisse, die in diesem Abschnitt präsentiert werden, wurden in dem Jupyter-Notebook unter folgender Adresse im Projekt erzeugt:

/wifimo/notebooks/DASU_data/EvaluationDistanceTrials.ipynb

In Fig. 2.5 wird die Amplitude aller Subträger, die während der Durchläufe gemessen wurde, für einige ausgewählte Durchläufe in Form von Heatmaps dargestellt. Eine Darstellung für alle ausgeführten Durchläufe findet sich im Jupyter-Notebook, das zur Experiment-Reihe gehört. Die Beobachtungen, die für die gezeigten Beispiele gemacht werden, können auf die restlichen Aufnahmen übertragen werden.

In den Darstellungen ist auf der x-Achse die Zeit (in Sekunden) nach Aufnahmestart zu sehen. Auf der y-Achse sind die Subcarrier-Indizes abgebildet, die zu den jeweiligen Subcarriern gehören. Die Farbe eines Pixels mit den Koordinaten (x,y) im Koordinatensystem zeigt die gemessene Amplitude des Subcarriers y zum Zeitpunkt x an. Hellere Pixel implizieren eine höhere Amplitude, dunklere Pixel eine niedrige Amplitude. Im unteren Rand der jeweiligen Heatmaps ist jeweils farblich hervorgehoben, ob zu einem Zeitabschnitt der Raum leer war (blau), ob die VP auf einer Stelle still gestanden ist (grün) oder ob die VP sich bewegt hat (rot).




Fig. 2.5: CSI-Amplitude (z-Achse / Farbgebung) aller Subträger-Indizes (y-Achse) entlang der Zeit (x-Achse) für ausgewählte Versuchs-Durchläufe der Distanz-Versuche.

Für Fig. 2.5 wurden 4 Durchläufe von unterschiedlichen Personen gewählt, bei denen jeweils der Ablauf “A2” ausgeführt wurde. Der Bewegungsablauf im Raum war also bei jedem der Durchläufe der Selbe. In den blau und grün hervorgehobenen Abschnitten (“Empty room” und “Standing”) findet jeweils keine Bewegung im Raum statt, während in den roten Abschnitten (“Moving”) eine Person an einem Fleck hin- und her-lief. Dieser Unterschied macht sich visuell bemerkbar durch Streifen, die sich über die Subcarrier-Indizes hinweg verbreiten. Die abwechselnd hellen und dunklen Streifen, die entlang der Zeit-Achse in den “Moving”-Abschnitten zu sehen sind, implizieren, dass dort starke Schwankungen der CSI-Amplitude über alle Subträger hinweg stattfinden. In den Abschnitten ohne Bewegung hingegen kann man sehen, dass diese Streifen sort nicht vorhanden sind und dass innerhalb dieser einzelnen Abschnitte ein homogenes Bild entlang der Zeit-Achse gehalten wird. Daraus folgt, dass bei Stillstand im Raum die CSI-Amplitude annähernd konstant bleibt und keine größeren Schwankungen stattfinden. Diese Beobachtungen bestätigen, dass sich über das Betrachten der CSI-Amplitude sehr gut erkennen lässt, ob Bewegung in einem Raum stattfindet.

Vergleicht man im Verlauf einzelner Durchläufe die Abschnitte ohne Bewegung, während denen der Raum entweder leer war oder eine VP still an einem Punkt stand, kann man erkennen, dass die Anwesenheit der VP und das Verändern der Position der VP im Raum Einfluss auf die CSI-Amplituden der Subträger hat. Man kann sehen, dass die CSI-Amplituden aller Subcarrier verschoben werden, sobald die VP den Raum betritt oder an einer neuen Position stehen bleibt. Ab dem Zeitpunkt des Stehenbleibens bleiben die CSI-Amplituden dann erneut konstant auf dem neuen Niveau. Demnach lässt sich während eines Durchlaufs auch klar erkennen, wenn die VP ihre Position geändert hat, bzw. ob sie den Raum betreten hat.

Vergleicht man allerdings den Verlauf der verschiedenen Durchläufe in Fig. 2.5, sieht man, dass die Änderungen der CSI-Amplituden beim Wechseln der Positionen im Raum keinem fixen Muster folgen. Vereinzelt lassen sich Gemeinsamkeiten feststellen. Z.B. sehen sich die Abschnitte "Standing Spot 5" und "Standing Spot 7" bei Durchlauf 04 und 12 jeweils sehr ähnlich. Im Abschnitt "Standing Spot 9" hingegen ist u.A. die Amplitude der Subträger mit Index ~20 bei Durchlauf 04 deutlich niedriger als bei Durchlauf 12. Ähnliche Unterschiede können auch für die restlichen Abschnitte und anderen Durchläufe gefunden werden. Interessant ist vor allem, dass die unterschiedlichen Durchläufe sich nicht nur darin unterscheiden, wie weit sich die Amplitude der Subträger beim Wechsel zwischen zwei "Spots" verschiebt, sondern teilweise auch darin, ob sich die Amplitude nach oben oder nach unten verschiebt. In Fig. 2.6 ist beispielhaft die CSI-Amplitude des Subcarriers 20 für dieselben 4 Durchläufe dargestellt wie in Fig. 2.5. Dort kann man sehen, dass sich die Amplitude beim Wechsel von "Spot 7" zu "Spot 9" in den Durchläufen 04 und 22 senkt, während sie bei den Durchläufen 12 und 16 leicht erhöht werden.




Fig. 2.6: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Distanz-Versuche.

Des weiteren kann man in Fig. 2.5 beobachten, dass bereits in den “Empty room”-Abschnitten, in denen sich niemand im Raum befand, teilweise große Unterschiede zwischen den Durchläufen bestehen. Z.B. kann man sehen, dass der Subträger 6 in den Abschnitten “Empty room before” und “Empty room after” bei den Durchläufen 04 und 22 eine sehr niedrige Amplitude aufweist, während sie bei den Durchläufen 12 und 16 deutlich höher ist. Die Amplitude von Subträger 40 ähnelt sich hingegen bei den Durchläufen 04, 12 und 16, während sie bei Durchlauf 22 deutlich höher liegt.

Diese Unterschiede sind deswegen bemerkenswert, da die räumlichen Begebenheiten zwischen den Durchläufen nicht verändert wurden und die Aufnahmen daher unter gleichen Bedingungen aufgenommen wurden. Lediglich die Zeit, zu der die Aufnahmen gemacht wurden, und die Anzahl der Personen, die sich in den restlichen Räumen des Flurs aufhielten war zwischen den Aufnahmen unterschiedlich. Letztere wurden angewiesen, in einiger Entfernung zum Versuchsaufbau zu bleiben. Demnach ist es unwahrscheinlich, dass deren Bewegungen oder Anwesenheit einen großen Einfluss auf die Messungen hatten. Ausschlaggebender könnte sein, dass die Anwesenheit dieser Personen damit korreliert, wie viele elektrische Geräte wie Laptops und Smart-Phones sich in der Umgebung befanden. Die Strahlung und

Netzwerkaktivität, die mit diesen Geräten einher kommt, kann ein wichtiger Einflussfaktor auf die Signalgüte der beobachteten Geräte, und somit die Amplitude des CSI-Signals, sein.

Daraus lässt sich schließen, dass es abseits von den räumlichen Begebenheiten und der Anwesenheit von Personen noch weitere Einflussfaktoren geben muss, die die CSI-Amplituden der Subcarrier auf ähnliche Weise beeinflussen wie die Anwesenheit einer (stillstehenden) Person.

Dieser Umstand ist eine große Hürde in Hinsicht auf die Erkennung von Anwesenheit besonders für ein mögliches out-of-the-box Modell. Wenn unbekannte Einflussfaktoren zu ähnlichen Mustern führen können, wie die Anwesenheit einer Person, gestaltet es schwierig, zu unterscheiden, welcher dieser Faktoren, für das jeweilige Muster verantwortlich ist. Diese äußeren Einflussfaktoren können z.B. Netzwerkaktivitäten in der Nähe des beobachteten Raums, die aktuelle Luftfeuchtigkeit oder Temperatur oder sonstige Umstände, die nicht erkannt wurden, sein. Für die zukünftige Entwicklung und für zuverlässige Vorhersagen ist es wichtig, die ausschlaggebenden Faktoren zu identifizieren, in zukünftigen Datensätzen mit aufzuzeichnen und in Modelle mit einfließen zu lassen.

2.5.4 Inkonsistente Sampling-Rate

Beim Betrachten der Zeitstempel der Rohdaten, zu welchen jeweils Messungen für die CSI aufgenommen wurde, haben wir festgestellt, dass die Messungen in unregelmäßigen Abständen gemacht wurden. Deshalb sollte genauer untersucht werden, wie sich die Sampling-Rate über die Versuchs-Durchläufe hinweg verhielt. Dafür wurde über die Durchläufe hinweg jeweils die Sampling-Rate der vergangenen Sekunde zu Zeit-Schritten von 0.2 Sekunden berechnet und in der Darstellung in Fig. 2.7 für alle Durchläufe dargestellt.

Zunächst können wir dort sehen, dass in allen Durchläufen mindestens ein längerer Abschnitt existiert, in dem sich die Sampling-Rate nahe bei ca. 85 Hz bewegt und in dem nur kleinere Schwankungen auftreten. In diesen Abschnitten wurde also annähernd eine fixe Sampling-Rate eingehalten.

Während einiger Durchläufe bleibt die Sampling-Rate über die gesamte Zeit hinweg sehr stabil nahe diesem Wert.

Bei anderen Durchläufen können wir allerdings sehen, dass stellenweise Einbrüche der Sampling-Rate stattfinden. So ist die Sampling-Rate z.B. in Durchlauf 11 in der zweiten Hälfte der Aufzeichnung nur noch bei durchschnittlich ca. 60 Hz, wobei sie in diesem Abschnitt auch stärkeren Schwankungen unterliegt. In anderen Durchläufen wie Nr. 18 & 22 findet der Einbruch nur in kürzeren Abschnitten statt, nach welchen sich die Sampling-Rate erneut auf ca. 85 Hz erhöht. In Durchläufen wie z.B. 16 oder 24 kann man außerdem eher punktuelle Einbrüche erkennen, die nur von kurzer Dauer sind.

Was die Schwankungen der Sampling-Rate verursachte, ist leider nicht bekannt. Interessant ist außerdem, ob es möglicherweise einen äußeren Einflussfaktor gibt, der sich sowohl auf die Sampling-Rate als auch auf die Ausprägung der CSI an sich auswirkt.

Da für die Methoden wie die Fast-Fourier-Transformation, die in den weiteren Analysen verwendet wurden, eine fixe Sampling-Rate vorausgesetzt wird, wurden die aufgezeichneten Daten in einem Preprocessing-Schritt auf durch Interpolation auf eine fixe Rate von 75 Hz angepasst. Durch diesen Wert wird ein Großteil der Information in den Abschnitten mit einer höheren Sampling-Rate erhalten und in den Abschnitten, in denen eine niedrigere Rate herrscht, wird nur vergleichsweise wenig artifizielle Information hinzugefügt.




Fig. 2.7(a): Entwicklung der Sampling-Rate während aller aufgezeichneten Versuchsdurchläufe




Fig. 2.7(b): Entwicklung der Sampling-Rate während aller aufgezeichneten Versuchsdurchläufe

2.5.5 Ergebnisse Anwesenheits- und Bewegungserkennung

Die Ergebnisse, die in diesem Abschnitt präsentiert werden, wurden in dem Jupyter-Notebook unter folgender Adresse im Projekt erzeugt:

`/wifimo/notebooks/DASU_data/ClassificationPipeline_DASU_Distanzen.ipynb`

Im Notebook kann die Länge und die Schrittweite der Fenster angepasst werden, in die die langen Aufnahmen unterteilt werden.

Die aufgenommenen Experimenten konnten in Abschnitte unterteilt werden, in denen einer von drei Fällen galt. Dadurch ließ sich jeder Zeitstempel, zu dem die CSI gemessen und gespeichert wurde, einer der folgenden Klassen zuordnen:

- “Empty_room”: Abschnitte, in denen der leere Raum aufgenommen wurde.
- “Standing”: Abschnitte, in denen sich eine Person still stehend im Raum befand.
- “Moving”: Abschnitte, in denen sich eine Person im Raum umher bewegte.

Basierend auf dieser Einteilung sollte ein Klassifikations-Modell trainiert werden, welches in der Lage ist, anhand der gemessenen Zeitreihen der CSI-Amplitude zu erkennen, zu welcher dieser 3 Klassen ein Zeitpunkt gehörte. Dafür wurde ähnlich vorgegangen, wie bei den 5-Sekunden Aufnahmen aus dem Vorgänger-Projekt. Die vorhandenen Daten sollten mittels der Fast-Fourier-Transformation (FFT) in die Frequenz-Domäne übersetzt werden. Die transformierten Daten wurden dann als Input für das Klassifikations-Modell “xgboost” verwendet.

Damit die FFT konsistente Ergebnisse für unterschiedliche Zeitreihen liefert, d.h. damit sie die Frequenz-Domäne für die Reihen in die selben Frequenz-Abschnitte unterteilt, ist sie darauf angewiesen, dass ihr nur Zeitreihen derselben Länge und mit der selben, fixen Sampling-Rate übergeben werden. Da festgestellt wurde, dass bei den Aufnahmen mehrmals Einbrüche in der Sampling-Rate stattfanden, wurden in einem ersten Preprocessing-Schritt alle Aufnahmen durch Interpolation auf eine fixe Sampling-Rate von 75Hz angepasst.

Danach haben wir die gesamten interpolierten Aufnahmen, die jeweils 260 Sekunden lang waren, in kleinere Abschnitte aufgeteilt. Für die Ergebnisse, die wir hier präsentieren, haben wir die Aufnahmen in 2-Sekunden-Fenster unterteilt. Dabei haben wir alle 0.4 Sekunden ein neues Fenster erstellt. Jedem Fenster wurde außerdem die Klasse zugewiesen, in der der letzte vorhandene Zeitstempel des jeweiligen Fensters lag. Übertragen auf eine Echtzeitanwendung ließe sich diese Unterteilung folgendermaßen verstehen:

Alle 0.4 Sekunden würde neu überprüft, ob sich derzeit jemand im Raum befindet oder ob sich jemand im Raum bewegt. Um das zu beurteilen, werden die Daten der vergangenen 2 Sekunden verwendet.

Da die Abschnitte jeweils unterschiedlich lange dauerten, wurden für die verschiedenen Klassen unterschiedlich viele Fenster erstellt. Dadurch entstand ein Ungleichgewicht zwischen den Klassen im Trainings-Datensatz. Um dieses Problem anzugehen, wurde jedem Fenster im Trainings-Datensatz ein Gewicht zugeteilt, welches anti-proportional zum Anteil der jeweiligen Klasse im Datensatz war.

Im Anschluss wurden die erhaltenen Fenster mit einer 4-Fold-Cross-Validation 4-mal in Trainings- und Test-Datensätze unterteilt. In jedem Durchlauf der Cross-Validation wurde auf die CSI-Amplituden aller Subträger der einzelnen Fenster die FFT angewendet. Ein “xgboost”-Modell wurde dann auf den FFT-Ergebnissen der Trainings-Fenster trainiert. Anschließend wurde das Modell auf den FFT-Ergebnissen der Test-Fenster evaluiert.

Die Einteilung in Trainings- und Test-Datensätze wurde auf zwei verschiedene Arten durchgeführt:

- **Variante 1:**
Bei der ersten Variante wurde ein Teil der gesamten Durchläufe als Trainings-Durchläufe und der restliche Teil als Test-Durchläufe ausgesucht. Anschließend wurden die Fenster aus den so unterteilten Durchläufen jeweils zu den Trainings- und Test-Datensätzen zusammengefügt. Dieses Vorgehen hatte zur Folge, dass dem trainierten Modell jeweils zwar die vollständigen Daten aus einzelnen Versuchs-Durchläufen präsentiert wurden, ihm die Daten aus den Test-Durchläufen jedoch völlig unbekannt waren.
- **Variante 2:**
Bei der zweiten Variante wurden die Fenster aller Durchläufe zu einem großen Datensatz zusammengefügt. Die Reihenfolge der Fenster wurde dann zufällig umsortiert, wodurch nicht mehr zuzuordnen war, welches Fenster zu welchem Durchlauf gehörte. Die umsortierten Daten wurden dann wiederum in Trainings- und Test-Datensätze unterteilt. Nach diesem Vorgehen beinhalteten sowohl die Trainings-, als auch die Test-Datensätze jeweils einen Teil der Fenster aus jedem Durchlauf.

Für die Evaluation wurde in beiden Varianten verglichen, wie oft bei den Test-Daten die vorhergesagten Klassen mit den tatsächlichen Klassen übereinstimmten und wie oft eine bestimmte Klasse fälschlicherweise einer bestimmten anderen Klasse zugeordnet wurde. Die Ergebnisse der 4 Durchläufe der Cross-Validation wurden jeweils gemittelt und werden für die beiden oben genannten Varianten getrennt präsentiert.

- **Variante 1:**
In Fig. 2.8 werden die Ergebnisse von Variante 1 der Cross-Validation mithilfe einer Confusion Matrix dargestellt. In dieser wird tabellarisch dargestellt, welcher Anteil der Fenster mit einer bestimmten (wahren) Klasse (zu sehen auf der y-Achse) einer bestimmten Klasse vom Klassifikations-Modell zugewiesen wurde (zu sehen auf der x-Achse).
Zunächst kann man sehen, dass von allen Fenstern, in denen sich eine Person im Raum bewegte ("Moving"), auch 84% korrekt erkannt wurden. Nur in 16% der Fälle wurde stattdessen bestimmt, dass eine Person stillstehend im Raum stand. In <1% wurde überhaupt nicht erkannt, dass eine Person im Raum war ("Empty room"). Bei den Abschnitten, in denen eine Person still im Raum stand ("Standing"), wurde zu 76% die richtige Entscheidung getroffen. 19% dieser Fenster wurden fälschlicherweise zur Klasse "Moving" klassifiziert und 5% wurden der Klasse "Empty room" zugeteilt. Die Ergebnisse für die Fenster der (wahren) Klasse "Empty room" sind im Vergleich zu den anderen beiden Klassen relativ durchwachsen. Nur in 49% der Fälle wurde korrekt erkannt, dass sich tatsächlich niemand im Raum befand, während in weiteren 48% fälschlicherweise entschieden wurde, dass eine Person still im Raum stand.
Wenn man die Ergebnisse dieser Klassifikation so uminterpretiert, dass man statt der drei verschiedenen Klassen nur erkennen möchte, ob eine Person anwesend ist, egal ob stehend oder in Bewegung, so kann man die Klassen "Standing" und "Moving" zusammenfassen. Dies wurde für die Ergebnisse in Fig. 2.9 getan. Dort wurden die beiden Klassen zur neuen Klasse "Present" zusammengefasst. Man kann dort sehen, dass sehr zuverlässig erkannt wird (97%), wenn eine Person anwesend ist. Unglücklicherweise wird in der Hälfte der Fälle (51%), wenn keine Person anwesend ist, trotzdem entschieden, dass eine Person anwesend sei.




Fig. 2.8: Confusion Matrix für das 3-Klassen Problem für Variante 1 der Cross-Validation.




Fig. 2.9: Confusion Matrix für die reine Anwesenheitserkennung für Variante 1 der Cross-Validation.

- **Variante 2:**

In Fig. 2.10 werden die Ergebnisse von Variante 2 der Cross-Validation dargestellt. Man kann sehen, dass die Fenster, an deren letztem Zeitpunkt sich keine Person im Raum befand (Klasse "Empty room"), mit einer Präzision von 96% korrekt erkannt wurden. In nur jeweils ca. 2% der Fenster, in denen der Raum leer war, entschied sich das Modell fälschlicherweise dafür, dass eine still stehende Person oder eine sich bewegende Person im Raum war.

Bei der Klasse "Moving", bei der sich eine Person im Raum bewegte, wurde ebenfalls eine hohe Präzision von 88% erreicht. Nur in 1% der Fälle wurde fälschlicherweise entschieden, dass niemand im Raum sei. In 11% der Fälle wurde entschieden, dass eine Person im Raum still steht und zur Klasse "Standing" gehörte anstatt sich zu bewegen.

Für die Klasse "Standing" lieferte das Modell ähnliche Ergebnisse. 82% der Fenster wurden richtig erkannt. Nur 2% wurden der Klasse "Empty room" zugeteilt. Bei 16% wurde eine herumlaufende Person erkannt ("Moving") statt einer stehenden Person. Wenn man die Ergebnisse dieser Klassifikation so uminterpretiert, dass man statt der drei verschiedenen Klassen nur erkennen möchte, ob eine Person anwesend ist, egal ob stehend oder in Bewegung, so kann man die Klassen "Standing" und "Moving" zusammenfassen. Dies wurde für die Ergebnisse in Fig. 2.11 getan. Dort wurden die beiden Klassen zur neuen Klasse "Present" zusammengefasst. Man kann sehen, dass reine Anwesenheit mit 98%-iger Präzision erkannt wird. Für die Klasse "Empty room" bleibt die ebenfalls sehr gute Präzision von 96%.




Fig. 2.10: Confusion Matrix für das 3-Klassen Problem für Variante 2 der Cross-Validation.




Fig. 2.11: Confusion Matrix für die reine Anwesenheitserkennung für Variante 2 der Cross-Validation.

2.5.6 Diskussion

Die Ergebnisse von Variante 1 der Cross-Validation liefern zwar eine sehr gute Präzision für die Anwesenheitserkennung. Unglücklicherweise wurde in zu vielen Fällen auch fälschlicherweise die Anwesenheit einer Person erkannt, obwohl der Raum menschenleer war. Das ist hauptsächlich darauf zurückzuführen, dass häufig verwechselt wurde, ob sich niemand im Raum befand oder ob jemand still im Raum stand. Wie bereits in den Visualisierungen der Durchläufe gezeigt wurde, sind die CSI-Amplituden dieser beiden Klassen sehr ähnlich, abgesehen von verschiedenen Durchschnittswerten. Da ähnliche Verschiebungen auch zwischen den unterschiedlichen Durchläufen beobachtet werden konnten, war bereits zu erwarten, dass die Unterscheidung dieser beiden Klassen problematisch wird.

Dem Klassifikations-Modell wurden in dieser Variante im Training nur Daten einzelner Durchläufe präsentiert und für die restlichen Durchläufe wurde es lediglich zur Evaluation verwendet. Die Ergebnisse deuten trotz der Schwierigkeiten darauf hin, dass in den Daten Muster vorliegen, die die Klassen voneinander unterscheiden. Die Pipeline, die für die hier angestellten Analysen zur Klassifikation erstellt wurde, macht sich insbesondere die Transformation der gemessenen Zeitreihen in die Frequenz-Domäne mittels der FFT zu Nutzen. Für die eigentliche Klassifikation wurde ausschließlich die Information aus der Frequenz-Domäne genutzt. Diese beinhaltet zwar viele Informationen über den Mittelwert der Zeitreihe im jeweiligen Fenster, regelmäßig auftretende Schwankungen, sowie über Störgeräusche in den Daten. Jedoch kann es sein, dass durch die Transformation wichtige Informationen verloren gehen, die eine Klassifikation noch zuverlässiger machen könnten. Andere Methoden wie neuronale Netze sind unter Umständen in der Lage, diese Muster basierend auf den Daten ohne Anwendung der FFT zu lernen und können so möglicherweise zu zuverlässigeren

Ergebnissen führen. Andererseits sind neuronale Netze dafür bekannt, dass sie mehr Trainingsdaten benötigen, als Methoden, die auf Entscheidungsbäumen basieren.

Die Ergebnisse von Variante 2 der Cross Validation deuten darauf hin, dass eine zuverlässige Anwesenheitserkennung sehr wohl möglich ist. Die Ergebnisse sind mit Vorsicht zu genießen, da das Klassifikations-Modell im Training einen Teil von jedem der Versuchs-Durchläufe gesehen hat und die Evaluation auf Daten der selben Durchläufe durchgeführt wurde. Es ist davon auszugehen, dass die Performance auf Daten, die in neuen Durchläufen entstehen würden, schlechter ausfallen würde. Dennoch kann man daraus schließen, dass ein Trainings-Datensatz, der möglichst viele verschiedene Muster beinhaltet, die in der realen Anwendung immer wieder auftreten, auch zu einem zuverlässigeren Modell führen wird.

2.6 Küchen-Versuche

Auf dieser Seite soll beschrieben werden, wie die "Küchen"-Versuche durchgeführt wurden, und ihre Ergebnisse sollen beschrieben und diskutiert werden.

2.6.1 Hintergrund

In der Küche im neuen Bürogebäude des DASU sollen verschiedene realistische Szenarios von verschiedenen Versuchspersonen gespielt werden, in denen unterschiedliche Bewegungen im Raum stattfinden. Der Raum wird in verschiedenen Zonen, nahe am und weiter entfernt vom Receiver, in denen sich die Versuchspersonen zeitweise aufhalten. Außerdem beinhalten die Abläufe Bewegungen, die gezielt auf den Receiver zu führen. Es soll untersucht werden, ob die Unterscheidung der Zonen oder der Bewegungsrichtung aus den Daten ersichtlich wird.

2.6.2 Fragestellungen

- Kann zuverlässig unterschieden werden, ob sich eine Person, in der Küche aufhält?
- Kann erkannt werden, ob sich die Person nahe am oder weiter entfernt vom Receiver aufhält?
- Kann erkannt werden, ob sich die Person direkt auf den Receiver zubewegt?

2.6.3 Äußere Begebenheiten

Zunächst soll in diesem Abschnitt beschrieben werden, in welchem Umfeld die Küchen-Versuche durchgeführt wurden.

- Die Versuche wurden innerhalb des neuen DASU-Büros ausgeführt. Die Räumlichkeiten befanden sich im Erdgeschoss eines mehrstöckigen Hauses. Im Gegensatz zum Raum aus der Distanz-Versuchsreihe standen dort die umgebenden Stockwerke nicht leer. Sowohl im darunter- als auch im darüberliegenden Stockwerk befanden sich noch weitere, von anderen Personen genutzte Räume. Welche Aktivitäten dort stattfanden, konnte demnach nicht beobachtet werden.
- Die Versuche fanden innerhalb der Küche des Büros statt. In ihrer Mitte steht ein großer runder Esstisch. Sie grenzt an einer Seite mit einem Fenster zu einem Fußgängerbereich im Äußeren (siehe Fig. 2.13(b)). Auf der Seite, an der sich die Arbeitsfläche befindet (Fig. 2.13(a)), grenzt der Raum an eine Toilette, die während der Aufnahmen nicht betreten wurde. Auf der Seite gegenüber dem Fenster nach außen grenzt die Küche an einen schmalen Flur. Hinter diesem befindet sich das Treppenhaus des Gebäudes. Gegenüber der Arbeitsfläche und dem Kühlschrank befand sich ein weiterer kleiner Tisch, der ebenfalls als Arbeitsfläche genutzt wird. Außerdem ist dort ein offener Türrahmen zum Serverraum. Zwischen den beiden Räumen befindet sich keine Türe. In diesem befindet sich ein PC, ein Server und einige Bürostühle. An der Fenster-Seite grenzt der Raum ebenfalls an die Außenwelt. Der Raumaufbau kann in Fig. 2.12 gesehen werden.

- Die Versuche wurden über 3 Tage verteilt. Sie fanden am 08., 09. & 10. August statt. Abhängig vom Zeitpunkt der Aufnahme befanden sich unterschiedlich viele Personen und dementsprechend unterschiedlich viele genutzte Geräte in der unmittelbaren Umgebung des Versuchsaufbaus.
- Im Treppenhaus, welches nur durch einen relativ dünnen Flur und zwei Wände von der Versuchs-Küche getrennt war, bewegten sich teilweise während den Aufzeichnungen mehrere Personen. Zeitweise arbeiteten Handwerker darin. Dies wurde jedoch nicht mit aufgezeichnet. Es ist nicht klar, in wie weit das die Aufnahmen gestört hat.
- In der Küche befanden sich durchgehend eine Kaffeemaschine, ein Kühlschrank und eine Mikrowelle als elektrische Geräte.

2.6.4 Versuchs-Aufbau und -Ablauf

Für die Versuche wurde die Küche unseres (neuen) Büros vorbereitet. Der Aufbau des Raums und seiner Umgebung kann in Fig. 2.12 gesehen werden. Ein Transmitter / Access Point (AP) wurde an einer Steckdose im nebengelegenen Serverraum auf einer Fensterbank mit einer Halterung befestigt. Der Receiver (RC) wurde in der Küche auf der Arbeitsfläche direkt neben dem Kühlschrank befestigt. Da sich die Mikrowelle auf dem Kühlschrank befand, war diese ebenfalls relativ nahe zum Receiver. Auf dem Boden wurde durch farbiges Klebeband außerdem ein Bereich markiert. Dieser sollte markieren, dass sich die VP "nahe dem Receiver" befand, solange sie in dem Bereich stand.

Da sich die beiden Geräte in unterschiedlichen Räumen befanden, war die direkte Verbindungslinie zwischen ihnen von einer Wand unterbrochen. Relativ nahe neben der Verbindungslinie befand sich jedoch auch der offene Türrahmen der die Räume miteinander verbindet.




Fig. 2.12: Aufbau und Raumplan der Küchen-Versuche



Fig. 2.13(a): Fensterwand (links), Arbeitsfläche (hinten) Rand der Eingangstüre (rechts)



Fig. 2.13(b): Fensterwand (links), Arbeitsfläche (mittig), Eingangstüre (entlang dem rechten Bildrand) und farbliche Markierung für den Bereich “nahe dem Receiver”



Fig. 2.13(c): Zweite Arbeitsfläche (mittig), Kaffeemaschine und Türrahmen zum Serverraum (links)



Fig. 2.13(d): Serverraum mit Fenstern nach außen

In den Versuchsdurchläufen sollten jeweils von einer einzelnen Versuchsperson (VP) realistische Szenarien durchgespielt werden, wie sie in einer alltägliche Küche auftreten können. Dafür wurden 3 verschiedene Abläufe geplant, in denen die VP jeweils für ca. 1:45 min in der Küche verschiedene, vorgegebene Aktivitäten ausführte. Bei der Planung der Abläufe wurde darauf geachtet, dass natürliche Bewegungen auf den Kühlschrank hin vorkamen. Da sich der Receiver direkt neben dem Kühlschrank befand, entstanden dadurch auch direkt Bewegungen hin auf den Receiver. Außerdem beinhaltete einer der Abläufe, die vorhandene Mikrowelle für einige Zeit laufen zu lassen, um möglicherweise Störgeräusche durch deren Strahlung zu verursachen.

Bevor die VP die Küche betrat, wurde nach dem Start der Aufnahmen jeweils eine Aufnahme ohne die Anwesenheit von Personen in der Küche von ca. 30 Sekunden gemacht. Die Eingangstüre der Küche wurde nach dem Betreten oder Verlassen des Raums immer geschlossen. Die Abläufe nach Betreten der Küche sahen folgendermaßen aus:

- **Ablauf 1:**

In diesem Ablauf wurde simuliert, dass die VP in die Küche kommt, um sich einen Kaffee zu machen und während dem Durchlaufen der Maschine eine gewisse Zeit lang relativ ruhig wartet. Die Kaffeemaschine wurde dabei nicht tatsächlich bedient.

- Die VP betritt die Küche.
- Die VP spielt vor, die Kaffeemaschine zu bedienen.
- Die VP geht zum Fenster, öffnet dieses und stellt sich wartend an das offene Fenster.
- Die VP wartet ca. 30 Sekunden, bis Kaffeemaschine "durchgelaufen" ist.
- Die VP nimmt die Tasse aus der Maschine und stellt sie auf den Esstisch.

- Die VP geht auf den Kühlschrank zu, öffnet ihn, entnimmt ihm einen Milchkarton und schließt ihn wieder.
- Die VP geht zurück zur Kaffeetasse auf dem Esstisch und füllt etwas Milch darin.
- Die VP geht wieder auf den Kühlschrank zu, öffnet ihn, stellt den Milchkarton zurück und schließt den Kühlschrank.
- Die VP nimmt die Kaffeetasse und verlässt den Raum wieder.
- **Ablauf 2:**
 In diesem Ablauf wurde simuliert, dass die VP etwas Gemüse schneidet, die Reste zum Müll bringt und danach den Raum wieder verlässt. Das Gemüseschneiden wurde nicht tatsächlich durchgeführt, sondern nur die Handbewegungen dabei sollten nachgestellt werden. Auf der Arbeitsfläche an der Wand zum Serverraum befand sich ein Teller, der als Schneidebrett fungieren sollte. Es sollten während dem Durchlauf 2 verschiedene Wege gelaufen werden. Einmal direkt auf den Kühlschrank hin und einmal ohne auf den Kühlschrank zuzulaufen.
 - Die VP betritt die Küche.
 - Die VP öffnet eine Schublade an der Arbeitsfläche neben dem Serverraum und entnimmt ihr ein Messer.
 - Die VP geht zum Kühlschrank, öffnet ihn und entnimmt ihm Gemüse.
 - Die VP geht zurück zur Arbeitsfläche und führt dort eine Schneidebewegung mit dem Messer in der Hand für ca. 30 Sekunden aus.
 - Die VP nimmt den Teller und das Messer, geht an der Fenster-Seite des Raums entlang zum Mülleimer unter der großen Arbeitsfläche. (Dieser Weg führt nicht auf den Kühlschrank zu.)
 - Die VP öffnet den Mülleimer, leert Essensreste vom Teller hinein und schließt ihn wieder.
 - Die VP spült das Messer in der Spüle über dem Mülleimer ab. (Der Wasserhahn wird dabei nicht tatsächlich betätigt.)
 - Die VP geht an der Fenster-Seite zurück zur kleinen Arbeitsfläche und legt dort den Teller und das Messer ab.
 - Die VP verlässt die Küche.
- **Ablauf 3:**
 In diesem Ablauf wurde simuliert, dass eine Pflanze auf dem Esstisch der Küche gegossen wird. Während dem Gießen sollte die VP einige Zeit innerhalb der Markierung in der unmittelbaren Nähe zum Kühlschrank stehen. Anschließend sollte sich die VP spielen, eine Mahlzeit aus dem Kühlschrank zu nehmen und diese in der Mikrowelle zu erwärmen. Die Mikrowelle wurde dabei tatsächlich mit maximaler Leistung angeschaltet. Nach einigen Durchläufen stellten wir außerdem eine mit Wasser gefüllte Tasse in die Mikrowelle, um Schaden durch Leerlauf zu verhindern.
 - Die VP betritt die Küche.
 - Die VP nimmt die Gießkanne von der kleinen Arbeitsfläche.
 - Die VP läuft am Kühlschrank vorbei zum Wasserhahn und füllt die Kanne. (Der Wasserhahn wurde nicht tatsächlich bedient.)
 - Die VP bleibt innerhalb der Markierung vor dem Kühlschrank stehen und gießt (imaginär) die Pflanze auf dem Esstisch für einige Sekunden.
 - Die VP stellt die Gießkanne zurück auf die kleine Arbeitsfläche.
 - Die VP geht auf den Kühlschrank zu, öffnet ihn und entnimmt ihm (imaginär) Essen.

- Die VP öffnet die Mikrowelle, schließt sie wieder und lässt sie auf maximaler Leistung laufen.
- Die VP setzt sich auf einen Stuhl am Esstisch und wartet im Sitzen für ca. 30 Sekunden.
- Die VP geht wieder zur Mikrowelle, schaltet sie aus, öffnet und schließt sie wieder.
- Die VP verlässt die Küche.

Bei jedem der Durchläufe wurde nach Verlassen des Raums ebenfalls die leere Küche für einige Zeit aufgenommen. Da die Aufnahmedauer auf 195 Sekunden festgesetzt war, die Dauer des Ablaufs von Person zu Person unterschiedlich war, blieb dafür für jeden Durchlauf unterschiedlich viel Zeit übrig.

Insgesamt wurden 27 der oben beschriebenen Durchläufe durchgeführt und aufgenommen. In den ersten 4 war die Dauer der Aufnahmen noch auf 240 Sekunden festgelegt. Da wir aber feststellten, dass die Abläufe schneller als erwartet beendet waren, wurde die Aufnahmedauer danach auf 195 Sekunden reduziert.

Es nahmen 7 verschiedene Personen teil, die jeweils unterschiedlich viele Durchläufe machten. Jeder der 3 Abläufe wurde insgesamt 9 mal durchgeführt. Jede beteiligte Person führte jeden Ablauf mindestens einmal aus.

Die Aufnahmen wurden an drei verschiedenen Tagen gemacht. Am 08.08.2023, 09.08.2023 und 10.08.2023 wurden jeweils 9 Aufnahmen mit je 3 verschiedenen Personen gemacht.

Die Rohdaten, die vom Aufnahme-Setup aufgezeichnet wurden, befinden sich in der Projektstruktur unter:

/wifimo/data/raw/08_DASU_kitchen/

Für jeden aufgezeichneten Durchlauf wurde dort ein Unterordner angelegt, der die Rohdaten in einer CSV-Datei und eine unscharf gemachte Version des jeweils aufgenommenen Videos enthält in den Dateien:

.../{experiment_name}-csi.csv

und

.../{experiment_name}-blurred_video.mp4

Die aus den Rohdaten extrahierten Informationen über Zeitstempel, CSI-Amplitude & -Phase, Subcarrier-Zugehörigkeit, Versuchspersonen, Kategorie und Experimenten-Namen finden sich für jeden Durchlauf unter:

/wifimo/data/processed/08_DASU_kitchen/{experiment_name}_compact.csv

2.6.5 Beschreiben des Labeling-Prozesses

Die erstellten .json-Dateien, die die erstellten Labels für diese Versuchsreihe enthalten, befinden sich in der Projektstruktur im Ordner:

/wifimo/data/annotations/08_DASU_kitchen/

Für jeden aufgezeichneten Durchlauf wurde dort ein Unterordner angelegt, der die .json-Datei für der jeweiligen Durchlaufs enthält:

.../{experiment_name}/{labeling_datei}.json

2.6.6 Visualisierung und Evaluation der Durchläufe

Die Ergebnisse, die in diesem Abschnitt präsentiert werden, wurden in dem Jupyter-Notebook unter folgender Adresse im Projekt erzeugt:

`/wifimo/notebooks/DASU_data/EvaluationKitchenTrials.ipynb`

Im Notebook können außerdem kleine Änderungen vorgenommen werden, um auszuwählen, welche Durchläufe der Versuchsreihe visualisiert werden sollen. Auch kann für die Visualisierung der CSI-Amplitude eines einzelnen Subcarriers der gewünschte Subcarrier-Index eingestellt werden.

2.6.6.1 Unterschiede zwischen Anwesenheit und Abwesenheit einer Person

In Fig. 2.14 und Fig. 2.15 wird erneut die Amplitude aller Subträger, die während der Durchläufe gemessen wurde, für ausgewählte Durchläufe dargestellt. Die Darstellungen für alle Durchläufe finden sich im zugehörigen Jupyter-Notebook.

In Fig. 2.14 und Fig. 2.15 werden die selben Daten dargestellt, d.h. die jeweiligen Heatmaps unterscheiden sich nicht. Der Unterschied liegt lediglich darin, wie die Labels erstellt wurden, die jeweils im unteren Bildrand der einzelnen Plots zu sehen sind.

Für die Darstellung in Fig. 2.14 wurde die Aktivität in die 3 Kategorien "Empty room" (blau), "Far away from receiver" (grün) und "Close to receiver" (rot) eingeteilt. Die Kategorien beschreiben jeweils, ob sich zu einem Zeitpunkt niemand im beobachteten Raum befand, ob sich eine Person außerhalb des Bereichs "nahe dem Receiver" aus Fig. 2.12 befand, oder ob sich eine Person innerhalb dieses Bereichs befand.

Für die Darstellung in Fig. 2.15 wurden die 3 Klassen "Empty room" (blau), "Person present" (grün) und "Walking toward receiver" (rot) definiert. Diese beschreiben, ob sich zu einem Zeitpunkt niemand im beobachteten Raum befand, ob sich eine Person anwesend war, sich aber nicht gezielt auf den Receiver hin bewegte, oder ob sich eine Person gezielt auf den Receiver zu lief. In dieser Variante wurden nur diejenigen Bewegungen der dritten Klasse zugeordnet, die gezielt auf den Receiver gerichtet waren, wodurch es möglich war, sich zwar im Bereich "nahe dem Receiver" zu befinden, ohne sich dabei auf den Receiver hin zu bewegen. Das war z.B. der Fall, wenn die VP zum "Pflanzen gießen" im markierten Bereich stehen blieb. Bei den 4 hier präsentierten Durchläufen wurden jeweils unterschiedliche Aktionen von den VPen ausgeführt. Demnach sind die aufgenommenen Abläufe nicht direkt miteinander vergleichbar, wie es bei den Visualisierungen in den Distanz-Versuchen der Fall war.




Fig. 2.14: CSI-Amplitude (z-Achse / Farbgebung) aller Subträger-Indizes (y-Achse) entlang der Zeit (x-Achse) für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Labeling-Variante 1.




Fig. 2.15: CSI-Amplitude (z-Achse / Farbgebung) aller Subträger-Indizes (y-Achse) entlang der Zeit (x-Achse) für ausgewählte Versuchs-Durchläufe der Distanz-Versuche. Labeling-Variante 2.

In den Darstellungen bestätigt sich zunächst eine der Beobachtungen aus den Distanzversuchen. Nämlich können wir erneut für die Abschnitte der Klasse “Empty room” feststellen, dass zwischen den verschiedenen Durchläufen gravierende Unterschiede bestehen, obwohl die räumlichen Begebenheiten und die Positionierung der Aufnahmegeräte unverändert blieb. Das legt die Vermutung nahe, dass auch in den Räumlichkeiten Einflussfaktoren bestehen, die die CSI-Amplitude ähnlich beeinflussen wie die Anwesenheit stillstehender Personen. Dieser Umstand hat zur Folge, dass die Unterscheidung zwischen Abschnitten, in denen keine Person anwesend ist, und Abschnitten, in denen eine Person ruhig im Raum steht, erschwert ist.

Des Weiteren kann man sehen, dass in den Abschnitten, in denen sich jeweils eine Person im Raum befand, unterschiedliche Muster auftreten. Das spiegelt wieder, dass in dieser Versuchsreihe in jedem Durchlauf verschiedene Aktionen und Bewegungen in unterschiedliche Richtungen stattfanden. Die Abläufe umfassten sowohl Abschnitte, in denen die jeweilige VP von einem Punkt zu einem anderen lief, an bestimmten Punkten im Raum eher kleinere Handbewegungen ausführte oder wartend an einer Stelle stand oder saß. In den meisten

Heatmaps in Fig. 2.14 lassen sich Übergänge erkennen zwischen Abschnitten, in denen sich starke Schwankungen der CSI-Amplituden durch vertikale Streifen bemerkbar machen, und Abschnitten, in denen über einen längeren Zeitraum hinweg ein homogeneres Bild gehalten wird. Anhand dieser Unterschiede lässt sich vermuten, zu welcher Zeit eine Person eher kleinere oder keine Bewegungen ausführt und wann eher ausschweifendere Bewegungen stattfanden.

Die Analysen aus den Distanz-Versuchen ergaben, dass eine besonders große Schwierigkeit darin besteht, einen leeren Raum von einem Raum, in dem eine Person stillsteht, zu unterscheiden.

Vergleicht man die Abschnitte, in denen während der Anwesenheit einer Person über einen längeren Zeitraum hinweg keine größeren Schwankungen in den CSI-Amplituden stattfanden, mit den "Empty room"-Abschnitten kann man im Großteil der Heatmaps sehen, dass verschiedene Verschiebungen der CSI-Amplituden aller Subträger stattfinden. Die Ausprägung der Unterschiede ist allerdings sehr unterschiedlich. So kann man z.B. in Durchlauf 25 deutlich sehen, dass besonders bei den Subträgern 20-30 deutlich höhere Amplituden zwischen Sekunden 83 und 105 vorliegen als in dem "Empty room"-Abschnitt des selben Durchlaufs. In Durchlauf 12 hingegen sind kaum Unterschiede auszumachen zwischen dem Abschnitt von 65 Sekunden bis 95 Sekunden und den "Empty room" Abschnitten.

Zuletzt sollen die Abschnitte betrachtet werden, in denen sich die VP'en in dem Bereich "nahe dem Receiver" befanden. Dort kann man beobachten, dass allgemein eine relativ hohe Dynamik in den CSI-Amplituden stattfindet. In den meisten dieser Abschnitte kann man in den Heatmaps vertikale Streifen sehen, die Schwankungen in den CSI-Amplituden implizieren. Betrachtet man außerdem beispielhaft die CSI-Amplitude der einzelnen Subträgers mit Index 10 in Fig. 2.16, ist zu erkennen, dass in diesen Abschnitten besonders starke Peaks der Amplitude nach unten auftreten. Eine mögliche Erklärung dafür ist, dass die Anwesenheit einer Person in unmittelbarer Nähe zum Receiver das übertragene Signal besonders stark blockiert und dadurch zeitweise für Einbrüche in der CSI sorgt. Diese nach unten gerichteten Peaks finden sich zwar überwiegend in den Abschnitten der Klasse "Close to receiver", sind allerdings auch kein absolutes Alleinstellungsmerkmal. So kann man z.B. in Fig. 2.16 bei Durchlauf 07 ungefähr bei Sekunde 70, bei Sekunde 135 und bei Sekunde 165 solche Peaks in den Abschnitten von "Far away from the receiver" beobachten. Auch bei Durchlauf 12 ist das ca. bei Sekunde 60 der Fall. Jedoch treten diese Peaks eher vereinzelt auf, während in den "Close to receiver"-Abschnitten häufig mehrere solcher Peaks schnell aufeinander folgen. Abgesehen davon können auch "Close to receiver" Abschnitte beobachtet werden, in denen keine solcher Peaks auftreten wie bei Durchlauf 07 im Abschnitt von ca. 135 bis 145 Sekunden.




Fig. 2.16: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Labeling-Variante 1.




Fig. 2.17: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Labeling-Variante 2.

Bei der Labeling-Variante 2, die in den Darstellungen in Fig. 2.15 und Fig. 2.17 gezeigt wird, kann man vor allem sehen, dass die Abschnitte der Klasse “Walking toward receiver” nur einen sehr kleinen Anteil an den gesamten Aufnahmen einnehmen. Das bestätigt, dass die Bewegung hin auf einen bestimmten Punkt nur von sehr kurzer Dauer ist und dass nur ein kurzes Zeitfenster besteht, um diese Bewegung rechtzeitig zu detektieren. Abgesehen davon lassen sich mit bloßem Auge keine eindeutigen Muster erkennen, die diese Kategorie von der Klasse “Person present”, während der sich die VP beliebig im Raum bewegte, trennt.

2.6.6.2 Einfluss von geöffnetem Fenster

Während einiger der Aufzeichnungen wurden die VP'en angewiesen, das Fenster, welches sich an der Außenwand der Küche befand, komplett zu öffnen. Dadurch sollte unter Anderem untersucht werden, welchen Einfluss die Veränderung von räumlichen Begebenheiten durch das Ändern der Position eines statischen Objekts auf die CSI-Amplitude hat. Das Fenster hat zusätzlich die Eigenschaft, dass es Reflektionen des WiFi-Signals verursacht, welche durch das Öffnen ebenfalls verändert werden.

In manchen Durchläufen wurde das Fenster nach einiger Zeit wieder geschlossen, in anderen blieb es bis zum Ende der Aufnahme geöffnet. In Fig. 2.18 und Fig. 2.19 werden die Heatmaps und die CSI-Amplitude für den einzelnen Subcarrier 15 für diese Durchläufe gezeigt. In den Darstellungen wird durch die blauen Markierungen indiziert, in welchen Abschnitten das Fenster jeweils offen stand.




Fig. 2.18: CSI-Amplitude (z-Achse / Farbgebung) aller Subträger-Indizes (y-Achse) entlang der Zeit (x-Achse) für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Markierungen für Abschnitte, in denen das Fenster im Raum offen stand.




Fig. 2.19: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Markierungen für Abschnitte, in denen das Fenster im Raum offen stand.

Besonders interessant sind hier diejenigen Durchläufe, bei denen das Fenster bis zum Ende der Aufnahme offen gelassen wurden, da dort die Abschnitte verglichen werden können, in denen zu Beginn und zum Ende der Aufnahme der leere Raum aufgenommen wurde. In diesen

Fällen unterscheiden sich die Abschnitte zum Anfang und zum Ende der Aufnahmen in den räumlichen Begebenheiten durch das offen stehende Fenster. Das ist in den Aufnahmen 3, 9, 12, 18, 21 und 24 der Fall.

Es lassen sich verschiedene Beobachtungen machen, abhängig davon, welchen der Durchläufe man betrachtet. Bei Durchlauf 03 z.B. kann man sehen, dass die Heatmap ab dem Zeitpunkt, an dem das Fenster offen steht, allgemein deutlich dunkler gefärbt ist. Das spricht dafür, dass die CSI-Amplitude aller Subträger verringert wird. In Fig. 2.19 kann man für den Subcarrier 15 ebenfalls die Absenkung der CSI-Amplitude für den leeren Raum erkennen. Die Absenkung ist in der Heatmap besonders stark für die Subcarrier mit niedrigem Index ausgeprägt. Bei den Subcarriern mit Indizes größer als 35 bleibt die CSI-Amplitude beinahe auf dem selben Niveau. Bei Durchlauf 24 kann man bei den Subcarriern mit niedrigen Indizes ebenfalls eine Absenkung der CSI-Amplitude erkennen, auch wenn diese nicht so stark ausgeprägt ist, wie bei Durchlauf 03. Die Subcarrier 15 - 30 bleiben nahezu unverändert, während bei den Subcarriern >30 sogar eine Erhöhung der CSI-Amplitude zu sehen ist. Dieses Muster kann ähnlich auch bei den Durchläufen 09 und 18 erkannt werden. Auch bei Durchlauf 21 kann das selbe Muster beobachtet werden, wobei die Ausprägung der Verschiebungen hier sehr gering sind. Bei Durchlauf 21 hingegen kann kaum ein Unterschied zwischen dem leeren Raum zu Beginn und zum Ende der Aufnahme erkannt werden, obwohl die Stellung des Fensters verändert wurde.

Diese Beobachtungen zeigen zunächst, dass die Stellung des Fensters in dieser Versuchsreihe die CSI-Amplitude beeinflusst hat, indem die CSI-Amplitude aller Subcarrier in ihrem Mittelwert längerfristig verschoben wurde. Die verschiedenen Subcarrier wurden jeweils unterschiedlich beeinflusst. Bei manchen führte das Öffnen des Fensters zu einer Verringerung, bei anderen zu einer Erhöhung der CSI-Amplitude. Bei wieder anderen war beinahe keine Veränderung zu sehen. Dieser Einfluss ähnelt auch dem Einfluss, den die Positionierung einer still stehenden Person auf die CSI-Amplituden zeigte.

Über die Durchläufe hinweg waren erneut unterschiedliche Muster zu sehen. Ob und auf welche Weise die Fensterstellung einen Einfluss hatte variierte zwischen den Durchläufen, ebenfalls wie bei der Positionierung einer stehenden Person. Es zeigte sich erneut kein eindeutiges Muster, das klar auf die Änderung des Zustands schließen lässt.

2.6.6.3 Einfluss einer laufenden Mikrowelle

Um einen weiteren, möglichen Einflussfaktor auf die CSI zu untersuchen, wurden die VP'en in einigen der Durchläufe angewiesen, für einige Zeit die Mikrowelle, die sich in unmittelbarer Nähe zum Receiver befand, laufen zu lassen. Die elektromagnetische Strahlung, die von dem Gerät ausgeht kann unter Umständen die Signale der WiFi-Kommunikation überlagern und so die CSI beeinflussen.

In Fig. 2.20 und Fig. 2.21 die CSI-Amplitude für die zwei Subcarrier 15 und 40 für diese Durchläufe gezeigt. In den Darstellungen wird durch die grünen Markierungen indiziert, in welchen Abschnitten die Mikrowelle aktiv war.




Fig. 2.20: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Markierungen für Abschnitte, in denen Mikrowelle auf maximaler Leistung angeschaltet war.




Fig. 2.21: CSI-Amplitude eines beispielhaften Subträgers entlang der Zeit für ausgewählte Versuchs-Durchläufe der Küchen-Versuche. Markierungen für Abschnitte, in denen Mikrowelle auf maximaler Leistung angeschaltet war.

In den Abschnitten, in denen die Mikrowelle aktiv ist fällt zuerst bei beiden gezeigten Subträgern auf, dass häufig extreme Ausschläge nach unten über längere Zeiträume hinweg und mit sehr hoher Frequenz auftreten. Dies kann vor allem in den Durchläufen 14, 17 und 26 beobachtet werden. Ähnliches ist auch bei den Durchläufen 02, 05 und 08 zu sehen. Während die

Mikrowelle aktiv ist, sind deutlich stärkere “Störsignale” in den Daten zu sehen, als sie sonst in den Abschnitten auftreten, in denen z.B. der leere Raum aufgenommen wurde. Ausreißer für diese Beobachtung sind nur die Durchläufe 20 und 23, bei denen zwar teilweise auch starke Ausschläge zu sehen sind, die allerdings im Vergleich zu den anderen Durchläufen eher von kurzer Dauer sind und nicht eindeutig der Aktivität der Mikrowelle zuzuordnen sind.

Die Beobachtungen legen nahe, dass sich der hier untersuchte Einflussfaktor hauptsächlich in Störgeräuschen mit hoher Frequenz bemerkbar macht. Z.B. durch die Anwendung eines lowpass-Filters oder durch smoothing-Strategien ließe sich dieser Faktor also vergleichsweise einfach aus den Daten entfernen. Durch die Anwendung der FFT im weiteren Kapitel über die Klassifikation in diesem Setting wird der Faktor ebenfalls von anderen Faktoren wie menschliche Bewegung isoliert, da sich diese in einem anderen Frequenz-Spektrum bemerkbar machen.

2.6.7 Ergebnisse Anwesenheits- und Bewegungserkennung

Die Ergebnisse, die in diesem Abschnitt präsentiert werden, wurden in dem Jupyter-Notebook unter folgender Adresse im Projekt erzeugt:

`/wifimo/notebooks/DASU_data/ClassificationKitchenTrials.ipynb`

Im Notebook kann die Größe und die Schrittweite der Fenster angepasst werden, in die die langen Aufnahmen unterteilt werden.

In dieser Experimentreihe wurde die Variante 1 des Labelings verwendet, um ein Klassifikations-Problem zu untersuchen, in dem die folgenden drei Klassen unterschieden werden sollten:

- “Empty_room”: Abschnitte, in denen der leere Raum aufgenommen wurde.
- “Far_away_from_receiver”: Abschnitte, in denen sich eine Person im Raum in einiger Entfernung zum Receiver befand.
- “Close_to_receiver”: Abschnitte, in denen sich eine Person im Raum in unmittelbarer Nähe zum Receiver befand.

Mit den so definierten Klassen wurde dasselbe Vorgehen für das Training und die Evaluation des Klassifikationsalgorithmus ausgeführt, welches in [Distanz-Versuche](#) beschrieben wurde. Das Zeitintervall und die Schrittweite für die Fenster, in die die großen Datensätze unterteilt wurden, betrugen jeweils 5 Sekunden und 0.5 Sekunden.

Auch für die Cross-Validation wurden dieselben beiden Varianten wie in [Distanz-Versuche](#) ausgeführt. Es wurden erneut jeweils eine 4-Fold-Cross-Validation ausgeführt und es werden die Mittelwerte dieser Durchläufe für die Kenngrößen (Confusion Matrices, Präzision) berichtet.

- **Variante 1:**

In Fig. 2.22 und Fig. 2.23 werden die Ergebnisse von Variante 1 der Cross-Validation mithilfe einer Confusion Matrix dargestellt.

Man kann sehen, dass diejenigen Fenster, in denen sich keine Person im Raum befand, zu 78% korrekt erkannt werden. In 19% der Fälle entscheidet das Modell stattdessen, dass sich eine Person im Raum, in einiger Entfernung, befindet. Nur in ca. 3% wird entschieden, dass eine Person unmittelbar vor dem Receiver stehe. In den Abschnitten, die zur Klasse “Far_away_from_receiver” gehören, wird in 63% der Fälle, die richtige Entscheidung vom Modell getroffen. Bei weiteren 20% wird zwar erkannt, dass sich die VP im Raum befindet, jedoch wird die Person dem Bereich “nahe dem Receiver” zugeordnet. Bei weiteren 17% wird fälschlicherweise ausgegeben, dass sich ein leerer Raum vorfände. Die Klasse “Close_to_receiver” wird am schlechtesten erkannt. Nur 36 % der Zeitpunkte, in denen sich eine Person direkt vor dem Receiver befand, wird das auch erkannt. In den meisten anderen Fällen (51%) wird dennoch die Anwesenheit der Person erkannt, jedoch wird sie dem Bereich abseits des Receivers zugewiesen. Nur in 13% wird ein leerer Raum vorhergesagt.

Das Modell verwechselt in den meisten Fällen die beiden Kategorien

“Far_away_from_receiver” und “Close_to_receiver“. Fasst man diese Klassen so zusammen, dass nur zwischen der Anwesenheit einer Person und dem leeren Raum unterschieden wird, so erhält man für die Anwesenheitserkennung, bzw. die Erkennung der Klasse “Present“, eine Präzision von 83%. D.h. dass nur in 17 Prozent der Zeitpunkte, in denen eine Person im Raum anwesend war, dies nicht erkannt wurde. Für die Klasse “Empty room” hingegen erhält man eine Präzision von 78%.




Fig. 2.22: Confusion Matrix für das 3-Klassen Problem für Variante 1 der Cross-Validation.




Fig. 2.23: Confusion Matrix für die reine Anwesenheitserkennung für Variante 1 der Cross-Validation.

- **Variante 2:**

In Fig. 2.24 und Fig. 2.25 werden die Ergebnisse der zweiten Variante der Cross-Validation dargestellt. Die Ergebnisse ähneln denen aus der ersten Variante sehr. Der markanteste Unterschied ist, dass die Präzision für die Klasse "Empty_room" um 13% höher, bei 91% liegt. Nur in ca. 9% der Fälle wird fälschlicherweise die Anwesenheit einer Person detektiert. Für die Klassen "Far_away_from_receiver" und "Close_to_receiver" ergibt sich ein ähnliches Bild wie bei Variante 1. Die reine Anwesenheitserkennung ergibt eine Präzision von 84%. In 16% der Fälle wird die Anwesenheit nicht erkannt. Die Unterscheidung der beiden Klassen, in denen eine Person anwesend ist, stellt das Modell erneut vor eine Herausforderung. Im Großteil der Fälle wird entschieden, dass sich die Person weit entfernt vom Receiver aufhält. Nur in 39% der Fälle, in denen sich die VP vor dem Receiver befindet, wird das erkannt. In 62% der Fälle, in denen die VP tatsächlich weiter entfernt vom Receiver ist, wird das richtig erkannt.




Fig. 2.24: Confusion Matrix für das 3-Klassen Problem für Variante 2 der Cross-Validation.




Fig. 2.25: Confusion Matrix für die reine Anwesenheitserkennung für Variante 2 der Cross-Validation.

2.6.8 Diskussion

Die Ergebnisse aus den Visualisierungen der Küchen-Versuche bestätigen einige Beobachtungen, die bereits in den Distanz-Versuchen gemacht wurden, nämlich, dass sich einige Einflüsse auf die Daten bemerkbar machen, die noch nicht identifiziert sind und deren Auswirkungen nicht klar vorhersagbar sind. Auch wie diese Einflüsse mit anderen aufgenommenen Faktoren, wie dem Öffnen eines Fensters, den Bewegungen und der Position einer Person oder der Aktivität einer Mikrowelle, interagieren, ist eher unregelmäßig. Dieser Zustand erschwert die korrekte Klassifikation verschiedener Szenarien, weswegen diese in der zukünftigen Entwicklung identifiziert und in die Modellierung mit einbezogen werden sollten.

Trotz alledem ergab sich für die Anwesenheitserkennung ein klares Bild, dass mit relativ hoher Wahrscheinlichkeit erkannt werden kann, wenn sich eine Person im Raum befindet. Die Präzision von 83%, bzw. 84%, ist ein guter Wert, besonders in der Hinsicht darauf, dass in dieser Versuchsreihe viele verschiedene Szenarien ausgeübt wurden, in denen auch Störfaktoren wie das Öffnen des Fensters oder die Aktivität der Mikrowelle eine Rolle spielten. Auch waren viele verschiedene Personen an den Durchläufen beteiligt, die zu unterschiedlichen Tagen und Tageszeiten aufgenommen wurden.

Zu den Schwierigkeiten für das Modell kommt hinzu, dass in dieser Versuchs-Reihe viele verschiedene Bewegungs-Muster zur Klasse "Far_away_from_receiver" zusammen gefügt wurden. Diese Klasse beinhaltete sowohl Abschnitte, in denen sich die VP'en im Raum umher bewegten, als auch solche, in denen sie wartend an einem Punkt standen oder saßen.

Außerdem waren die Bewegungen der Klasse "Close_to_receiver" manchen Bewegungen aus der anderen Klasse sehr ähnlich, und unterschieden sich hauptsächlich durch die Position im Raum, an der sie stattfanden.

Bemerkenswert ist, dass in Variante 1 der Cross-Validation, in der der Test-Datensatz nur Daten aus für das Modell völlig unbekannten Versuchs-Durchläufen beinhaltete, bereits gute Ergebnisse für die Präzision von Anwesenheit und Abwesenheit erreichte. Das steht im Gegensatz zu den Ergebnissen der selben Variante aus den Distanz-Versuchen, wo das trainierte Modell überwiegend zu Gunsten der Klasse "Present" entschied. Auch in den Fällen, in denen die VP nicht im Raum war.

In Hinblick auf die relativ geringe Größe des Trainings-Datensatzes und die dafür hohe Anzahl an Einflussgrößen, deuten die hier erreichten Ergebnisse darauf hin, dass mit einem wachsendem Datensatz und besser ausgearbeiteter Modellierung eine zuverlässige Anwesenheitserkennung möglich ist.

3 Einfluss- / Störfaktoren auf das WiFi-, bzw. CSI-Signal

Geräte, die über eine WiFi-Verbindung miteinander kommunizieren, senden ihre Signale auf mehreren sog. Subträgern aus. Jedem dieser Subträger wird eine feste Frequenz zugewiesen, zu der er sendet, wobei sich diese von der Frequenz jedes anderen Subträgers unterscheidet. In den gängigen WiFi-Netzwerken, wie man sie in den meisten Haushalten vorfindet, befinden sich diese Frequenzen im 2,4 GHz-, seltener im 5 GHz-, Band.

Die unterschiedlichen Übertragungsfrequenzen der Subträger sorgen dafür, dass jeder Subträger andere Übertragungspfade im Raum verfolgt. Einerseits werden die Signale auf direktem Weg zwischen Transmitter und Receiver übertragen, andererseits ergeben sich Pfade durch Reflektionen an Oberflächen, die sich in der Umgebung um die beiden Geräte befinden. Durch die unterschiedlichen Übertragungspfade ist es möglich, dass die Signale einzelner Subträger stärker oder schwächer von Phänomenen wie Fading beeinflusst werden. Dadurch ist die "Güte" des übertragenen Signals für jeden Subträger anders, was sich in unterschiedlichen Amplituden des CSI-Signals auswirkt. Unter gleichen Bedingungen, also in einem leeren Raum, in dem keine Möbel verschoben wurden, Fenster und Türen unverändert bleiben, keine anderen Geräte im Einsatz sind, etc. sollten die Bedingungen stabil sein und die Übertragung unverändert bleiben.

In den Daten, die aus dem Vorgänger-Projekt mit Helbling zur Verfügung standen, und die aus unseren eigenen Experimenten entstanden, konnte allerdings beobachtet werden, dass selbst bei Abwesenheit von Personen in einem Raum, unterschiedliche Muster in den CSI-Amplituden von Zeit zu Zeit auftraten. Dies liegt mit großer Wahrscheinlichkeit daran, dass es außer der Anwesenheit von Personen noch andere äußere Einflussfaktoren gibt, die sich zwischen den Aufnahmen änderten, aber nicht genau identifiziert werden konnten. Einige mögliche Einfluss- und Störfaktoren auf das Verhalten der CSI-Signale der beobachteten Subträger sollen hier aufgelistet werden.

3.1 Frequenzband und Kanal der Übertragung zwischen Transmitter und Receiver

In haushaltsüblichen Netzwerken werden aktuell hauptsächlich die **Frequenzbänder** nahe 2,4 GHz und 5 GHz verwendet. Welches dieser Bänder für die Übertragung ausgewählt wird kann schon großen Einfluss auf die Güte des Signals und wie dieses von Reflektionen, Dämpfungen und Distanzen beeinflusst wird haben. Das 5 GHz Band wird z.B. bei größer werdender Distanz zwischen RC und TR schneller abgeschwächt. Andererseits wird das 2,4 GHz Band von mehr Geräten beeinflusst, die mit einer ähnlichen Frequenz arbeiten (z.B. Mikrowellen).

Innerhalb dieser beiden Frequenzbänder bestehen außerdem noch mehrere **Kanäle**, die die Bänder in noch kleinere Frequenz-Abschnitte unterteilen. Die Geräte wählen auch hier für die Kommunikation einen aus, und teilen aus diesem Abschnitt bestimmte Frequenzen den Subträgern zu. Je nachdem, welcher Kanal gewählt wird, variiert also die Frequenz, zu der ein Subträger sendet, wodurch ebenfalls beeinflusst werden kann, wie auf Reflektionen, etc. reagiert wird. Hinzu kommt, dass das Frequenzband manchen Kanäle überschneidet, wodurch Interferenzen entstehen können.

In den Versuchen, die im Rahmen dieses Projekts ausgeführt wurden, wurde, soweit ersichtlich, immer das Frequenzband 2,4 GHz und der Kanal "1" gewählt. Somit sollte jeder Subträger immer mit der gleichen Frequenz gesendet haben.

3.2 Netzwerkaktivität im gleichen und in umliegenden Netzwerken

Neben dem Netzwerk, das vom Transmitter aus den Versuchsreihen aufgebaut wird, bestehen in der unmittelbaren Umgebung noch weitere Netzwerke, mit denen das 2,4 GHz Frequenzband geteilt wird. Durch die IEEE-Standards, die zur Netzwerkeinteilung bestehen, werden Netzwerken, die räumlich gesehen nahe beieinander liegen, nach Möglichkeit Kanäle zugeteilt, die sich nicht überlagern. Da es aber in diesem Band in Europa nur 13 verschiedene Kanäle gibt, ist die Auswahl dabei begrenzt und es ist möglich, dass Netzwerke in der Umgebung bestehen, die auf dem gleichen Kanal senden. (siehe: [WLAN-Frequenzen und WLAN-Kanäle \(elektronik-kompodium.de\)](http://elektronik-kompodium.de))

Die Vermutung liegt nahe, dass besonders die **Anzahl der Netzwerke** und die **Aktivität in diesen Netzwerken**, die den gleichen Kanal nutzen, wie die Geräte, die für die Aufnahmen der CSI verwendet werden, die Aufnahmen maßgeblich beeinflussen. Gleichzeitig ist davon auszugehen, dass auch in dem Netzwerk, in dem sich der beobachtete Receiver befindet, Aktivität von anderen Geräten wie PCs und Smartphones stattfindet. Die **Auslastung des beobachteten Netzwerks** kann ebenfalls eine Einflussgröße sein auf die Verbindung zum beobachteten Receiver.

In den Versuchen wurden alle Netzwerke in der Umgebung identifiziert und aufgezeichnet, die zu Beginn eines Versuchs-Durchlaufs verfügbar waren. Dabei wurde unter anderem dokumentiert, welchen Kanal die jeweiligen Netzwerke nutzten. Es konnte beobachtet werden, dass die Netzwerke, die das 2,4 GHz-Band nutzten, ausschließlich die Kanäle 1, 6 & 11 nutzten, welches Kanäle sind, deren Frequenz-Bereiche sich nicht überschneiden. Das Netzwerk, das vom Transmitter der Versuche aufgebaut wurde, nutzte immer den Kanal "1". In einigen Durchläufen konnte beobachtet werden, dass andere Netzwerke bestanden, die den gleichen Kanal nutzten. Die Netzwerke in den Büroräumen, in denen die Versuche durchgeführt wurden, (DASU und DASU-Gast), also die, die lokal am nächsten waren, nutzen einen anderen Kanal.

Von dem Versuchs-Transmitter wurde ein eigenes Netzwerk aufgebaut, zu dem ausschließlich der Versuchs-Receiver eine Verbindung aufgebaut hat. Demnach nutzten dieses Netzwerk keine anderen Geräte und es gab keine Netzwerkaktivität in diesem Netz außer der Kommunikation zwischen diesen beiden Geräten.

3.3 Positionierung von Transmitter und Receiver

In dem Paper *Modeling and Quantitative Analysis of Motion Detection in CSI-Based Sensing* wird näher auf die Ausbreitung von Signalen über verschiedene (räumliche) Pfade eingegangen. Abhängig von der direkten Verbindungslinie zwischen Transmitter und Receiver werden die sogenannten **Fresnel-Zonen** eingeteilt. Dies sind Ellipsoide mit den betrachteten Transmitter und Receiver als Brennpunkte und unterschiedlichen Ausdehnungen. Es legt nahe, dass Veränderungen innerhalb einer Zone relativ ähnliche Auswirkungen auf die Übermittlung des Signals haben und dass sich Veränderungen in unterschiedlichen Zonen unterschiedlich auswirken.

In Fig. 3.1 wird beispielhaft gezeigt, wie diese Ellipsoide aussehen können. Man kann sehen, dass im Innersten eine Zone besteht, die den direkten Verbindungspfad enthält, während in den äußeren Zonen Pfade enthalten sind, die durch Reflektion zustande kommen. In dem Bereich zwischen den beiden Geräten besitzen die Zonen jeweils eine relativ große Fläche. Befindet man sich allerdings räumlich gesehen "hinter" einem der Geräte, so folgen die Zonen sehr dicht aufeinander.




Fig. 3.1: Fresnel-Zonen bei der Kommunikation von Transmitter und Receiver

Es ist wahrscheinlich, dass Änderungen in den **inneren Zonen** stärkere Auswirkungen haben als in **äußeren Zonen**. Da die inneren Zonen den Hauptteil ihrer Fläche zwischen den Geräten einnehmen, kann man die Hypothese aufstellen, dass Veränderungen und Bewegungen besonders in diesem Bereich großen Einfluss auf das Signal haben und detektiert werden können. Anhand des Ausmaßes der beobachteten Veränderungen kann möglicherweise auch festgestellt werden, ob Bewegungen auf der Achse zwischen den Geräten oder abseits davon stattfindet.

Da die inneren Zonen "hinter" den Geräten allerdings nur sehr wenig Fläche einnehmen, ist fraglich, ob Änderungen oder Bewegungen dort zuverlässig erkannt werden können.

Man kann sich einfach vorstellen, dass in der Realität sowohl solche Fälle auftreten, in denen die Bewegungen, die detektiert werden soll, zwischen den Geräten stattfindet, aber auch solche, in denen sich diese Bewegung abseits dieser Strecke abspielt. Diese Fälle werden aber sehr wahrscheinlich unterschiedlich behandelt werden müssen.

3.4 Räumliche Begebenheiten

Die Übertragung des Signals zwischen 2 Geräten wird maßgeblich von den räumlichen Begebenheiten zwischen ihnen und um sie herum beeinflusst. Wie im letzten Abschnitt über die Positionierung der Geräte erklärt, ist auch hier wahrscheinlich, dass besonders der Zustand im Raum zwischen den beiden Geräten den größten Einfluss hat.

Durch die Versuche konnte beobachtet werden, dass eine Änderung der räumlichen Begebenheiten, z.B. durch das Offen-stehen-lassen einer Türe oder eines Fensters, zu Verschiebungen der Amplitude der CSI in den verschiedenen Subträgern führten. Es konnte allerdings keine Regelmäßigkeit festgestellt werden, ob diese Verschiebungen nach oben oder unten stattfanden, welches Ausmaß sie hatten und ob einzelne Subträger immer auf die gleiche Art und Weise beeinflusst wurden.

Solange die räumlichen Begebenheiten konstant blieben und keine Veränderung oder Bewegung stattfand, konnte wiederum beobachtet werden, dass die CSI-Amplituden aller Subträger weitgehend stabil auf einem fixen Wert blieben. Das eröffnet Möglichkeiten, über Muster, die sich über länger beobachtete Zeiträume abzeichnen, erkannt werden kann, dass sich niemand in einem Raum aufhält. Z.B. wenn über mindestens 1 Minute keinerlei Bewegung erkannt wurde, kann mit hoher Wahrscheinlichkeit angenommen werden, dass das zurückliegende Signal Abwesenheit widerspiegelt. Finden Verschiebungen der CSI-Amplitude statt, kann ein System die Anwesenheit einer oder mehrerer Personen feststellen und

möglicherweise in einem nächsten Schritt die Veränderung als “Stillstehen” oder “Bewegung” klassifizieren.

Hier sollen noch einige Einflussfaktoren auf die räumlichen Begebenheiten aufgelistet werden:

- **Wände:**
 - Die Präsenz von Wänden zwischen den Geräten dämpft das Signal.
 - Wie viele Räume (und damit) Wände befinden sich zwischen den Geräten?
 - Aus welchem Material bestehen sie? (Nasse) Gipswände und Holz dämpfen z.B. stärker als Beton.
- **Wasserrohre und Kabel:**
 - Von Kabeln, die in Wänden zwischen den Geräten verlegt sind, kann je nach Nutzung und Isolierung störende Strahlung ausgehen.
 - (Gefüllte) Wasserrohre zwischen den Geräten können besonders dämpfend wirken. Besonders wenn das Wasser in Bewegung gesetzt wird, z.B. durch Aufdrehen des Wasserhahns, kann das möglicherweise die CSI beeinflussen, ähnlich wie menschliche Bewegung.
 - Wasser in Rohren des beobachteten Raums (Küche) kann z.B. auch durch Aktivität in anderen Zimmern (Bad) bewegt werden und somit trotzdem die Begebenheiten im beobachteten Raum beeinflussen.
- **Möbelstücke:**
 - Tische, Stühle, Arbeitsplatten, Schränke, etc. stehen im Raum und können dämpfend auf das Signal wirken. Je nach Beschaffenheit sorgen sie auch für Reflektionen und Streuungen.
- **Fenster:**
 - Sorgen besonders für Reflektionen und beeinflussen damit möglicherweise die Pfade, auf denen die Signal-Übertragung stattfindet.
 - Öffnen kann außerdem Luftfeuchtigkeit beeinflussen. (Siehe nächster Abschnitt)
- **Türen:**
 - Steht eine Türe offen, steht sie ähnlich zu einem Möbelstück als Hindernis im Raum.
 - Zusätzlich werden Pfade, die durch Reflektion oder Streuung auf deren Oberfläche zustande kamen, verändert.
- **Haushaltsgeräte:**
 - Geräte, wie Kühlschränke, Mikrowellen, Backöfen, etc. bestehen oft aus speziellem Material, welches sich besonders stark dämpfend oder reflektierend auf WiFi-Signale auswirken kann. Ihre Positionierung im Raum kann eine besonders wichtige Rolle einnehmen.
- **Staubsauger-Roboter:**
 - Diese Roboter unterscheiden sich von anderen Objekten hauptsächlich darin, dass sie im Betrieb nicht statisch sind, sondern sich durch den Raum bewegen. Im Vergleich zu menschlichen Bewegungen sind die der Roboter eher langsam. Außerdem unterscheiden sie sich in der Größe und Masse. Durch diese Dynamik können sich neue Muster in den gemessenen Signalen ergeben, die zu berücksichtigen sind.
 - Die Roboter kommunizieren in der Regel mit einer Station über Funksignale. (Weitere Beschreibung unter “Andere Elektrogeräte”)

- **Glas / Spiegel:**
 - Spiegelnde Oberflächen sorgen für mehr Reflektion als andere. Dementsprechend können diese das WiFi-Signal auf eine andere Art und Weise beeinflussen.

3.5 Andere Elektrogeräte

Viele haushaltsübliche Elektrogeräte emittieren elektromagnetische Strahlung, die unter Umständen zu Interferenzen mit dem beobachteten Netzwerk führen. Besonders interessant sind Geräte, die starke Strahlung verwenden, um Hitze zu erzeugen, wie z.B. Mikrowellen-Öfen oder (Induktions-)Herde.

Generell können die Signale von Geräten, die Funk-Signale nutzen, mit den WiFi-Signalen interferieren und so für Störungen sorgen. Z.B. kommunizieren **Staubsauger-Roboter** im Betrieb mit ihrer Lade-Station. Aber auch **Fernbedienungen** aller Art fallen in diese Kategorie. Die Frequenz, die z.B. von **Induktionsherden** ausgeht liegt lediglich im kHz-Bereich, weit abseits der GHz-Bereiche des WiFi-Signals, weswegen dies vermutlich ein eher unwesentlicher Störfaktor ist.

Haushaltsübliche **Mikrowellen**-Öfen hingegen verwenden eine Frequenz von 2,450 GHz, was ebenfalls im 2,4 GHz Band der WiFi-Netzwerke liegt. Die Strahlung wird zwar weitestgehend nach außen abgeschirmt, dennoch konnte in einigen der Küchen-Versuche beobachtet werden, dass in Zeitabschnitten, in denen der Mikrowellen-Ofen auf maximaler Leistung verwendet wurde eine deutlich stärkere Varianz in der CSI vorhanden war als in vergleichbaren Zeitabschnitten mit ausgeschalteter Mikrowelle.

Dies schien einen Frequenzbereich in den CSI-Zeitreihen zu betreffen, der deutlich höher liegt, als der Bereich, in dem menschliche Bewegungen stattfanden. Demnach kann angenommen werden, dass dieser Störfaktor z.B. über einen low-pass Filter behoben werden kann.

In unseren Auswertungen und beim Feature-Engineering für die CSI-Daten wurden die Zeitreihen über die Fast-Fourier-Transform (FFT) in den Frequenzbereich übersetzt. Über diesen Weg kann man auch den Frequenzbereich identifizieren, der durch die Aktivität der Mikrowelle beeinflusst wird, und folglich gesondert behandeln. Z.B. könnte man den Bereich beim Konstruieren von Input-Features abschneiden.

Generell Funk-Geräte

3.6 Bewegungen und Aktivität außerhalb des betrachteten Bereichs

Eine Herausforderung ist, Einflüsse auf die gemessenen Signale, die von der Welt außerhalb des beobachteten Bereichs kommen, zu berücksichtigen.

Zunächst gibt es in der Außenwelt zunehmend viele Faktoren, die elektromagnetische Strahlung aussenden und somit WiFi-Signale unterschiedlich stark beeinflussen können. Die am häufigsten auftretenden sind voraussichtlich Technik, die in vorbeifahrenden (**Elektro**-) **Autos**, verbaut ist, oder Strahlung, die von **Straßenbahnen** ausgeht.

Auch das **Mobilfunknetz** kann eine Einflussgröße sein.

Außerdem besteht eine weitere Schwierigkeit darin, **Bewegungen** innerhalb eines betrachteten Bereichs von denen, die **außerhalb** stattfinden, zu unterscheiden. Ist der Receiver z.B. an der Außenwand eines Hauses angebracht, können unter Umständen Bewegungen von Menschen, die am Haus vorbei laufen, zu ungewünschter Bewegungserkennung führen.

Hier sollte zusätzlich bedacht werden, dass in Umgebungen wie Mehrfamilienhäusern potentiell auch Aktivität von benachbarten Wohnungen gemessen werden kann. Daraus ergeben sich

zusätzlich Fragen über den Umgang mit der Privatsphäre anderer Menschen und über den Datenschutz.

3.7 Luftfeuchtigkeit

Die **Luftfeuchtigkeit** in einem Raum schwankt permanent und wird auch durch längere Anwesenheit von Personen beeinflusst. Außerdem kann das Öffnen von Fenstern und Türen die Luftfeuchtigkeit beeinflussen. Da Wasser WiFi-Signale dämpft, wäre es möglich, dass dies ebenfalls ein Faktor ist, der die CSI beeinflusst.

3.8 Konfiguration bei Programmstart

Das Programm, welches zur Aufzeichnung der CSI verwendet wurde, wurde nicht von uns selbst aufgesetzt. Deshalb ist nicht im Detail bekannt, ob und wie sich die Geräte beim **Start des Programms konfigurieren** und ob diese Konfiguration Einfluss auf die CSI der unterschiedlichen Subträger hat.

Um diesen Störfaktor zu untersuchen, wurde das Programm nach jeder Aufnahme während den Versuchen neu gestartet. Außerdem wurde während den Küchen-Versuchen der Transmitter nach jeder Aufnahme vom Strom getrennt und neu gestartet. Trotz den Neu-Starts sah die gemessene CSI von Aufnahmen des leeren Raums, die direkt nacheinander gemacht wurden sehr ähnlich aus. Deswegen kann vermutet werden, dass dieser Punkt keinen Einfluss hat.

4 Literatur-Liste

- **WiFi Sensing on the Edge: Signal Processing Techniques and Challenges for Real-World Systems:**
 - Meta-Studie, die Erkenntnisse über CSI-data collection, data processing, feature selection und machine learning Methoden erklärt und vergleicht. Wichtigste Erkenntnisse:
 - (Fast) alle Publikationen über das Thema gehen von Laborbedingungen aus und ignorieren Transfer in die echte Welt. Dadurch werden keine Langzeiteinflüsse beachtet, die in Algorithmic beachtet werden müsste.
 - Dimensionality reduction kann durch PCA oder "subcarrier correlation" durchgeführt werden.
 - Bei Missing (CSI-) Frames kann / sollte Interpolation durchgeführt werden.
 - Sampling Raten ab ca. 50 Hz waren ausreichend für die verschiedenen Klassifikations-Beispiele im Paper. Die meisten untersuchten Papers nutzten Sampling Raten von 100 - 800 Hz.
 - Amplitude ist wichtiger für hohe Accuracy Werte als die Phase der CSI.
 - Denoising Filter tragen nur minimal zu besseren Ergebnissen bei.
- **A Research on CSI-based Human Motion Detection in Complex Scenarios:**
 - Paper zur Detektion von "angestrenzter" / hektischer menschlicher Bewegung. Es wird Wert auf die Unterscheidung zwischen "Line-of-sight"- und "Non-line-of-sight"-Szenarien gelegt, was impliziert, dass Bewegung direkt zwischen Receiver und Transmitter zu anderen Mustern in der CSI führt als Bewegung außerhalb der Verbindungslinie.
- **A CSI-Based Human Activity Recognition Using Deep Learning:**
 - Nutzt 1D- und 2D- Convolutional Neural Networks (CNNs), um ohne feature-extraction durch die Forschenden Klassifikation zu machen.
- **Fine-grained CSI fingerprinting for indoor localisation using convolutional neural network:**
 - Befasst sich mit der Erkennung der Position von zwei Geräten in einem Raum durch Lernen spezifischer Muster, die zu den vorbestimmten Positionen gehören. Nutzt ebenfalls CNNs.
- **DensePose From WiFi:**
 - Es werden CSI-Daten von einem MIMO-System gesammelt. Mithilfe von parallel aufgenommenen Videos wird ein neuronales Netz (NN) trainiert, das aus den CSI-Daten rekonstruieren kann, wie sich Menschen im Raum positionieren.
 - Außerdem wird beschrieben, wie die Phase-Information der CSI-Daten aufbereitet werden kann, um als Input für das NN effektive genutzt werden zu können.
- **Wi-Fi-Based Fall Detection Using Spectrogram Image of Channel State Information:**
 - CSI-Daten werden mittels Fourier Transformation in Spektrogramme übersetzt, womit mittels CNN Fall-Bewegungen detektiert werden.
- **For better CSI Fingerprinting based Localization: a novel phase sanitization method and a distance metric:**
 - Beinhaltet relativ detaillierten Algorithmus zur Aufbereitung der CSI-Phase.
- **Modeling and Quantitative Analysis of Motion Detection in CSI-Based Sensing:**

- Nutzt physikalisches und probabilistisches Modell, um Bewegung zu erkennen und zu lokalisieren.
Die Rolle von "Fresnel-Zonen" wird beschrieben, anhand von denen erklärt werden kann, dass Bewegungen in verschiedenen elliptischen Zonen, die CSI, oder allgemein die WiFi-Übertragung, unterschiedlich beeinflussen.
- **Tracking vital signs of a patient using channel state information and machine learning for a smart healthcare system:**
 - CSI wird verwendet, um Atemfrequenz von Versuchspersonen zu bestimmen. Dazu werden mehrere Filter angewandt, um "Noise" aus den Daten zu beseitigen. Außerdem wird beschrieben, dass sich gewisse Änderungen in manchen Subträgern stärker bemerkbar machen als in anderen.
- **Distributed CHannel Sounder by University of Stuttgart (DICHASUS):**
 - Projekt der Uni Stuttgart, in dem (sehr viele) verschiedene Receiver und Transmitter in großen Räumen aufgestellt wurden und verschiedene Experimente z.B. zur Lokalisierung von Personen oder Objekten durchgeführt wurden. Die Daten sind öffentlich verfügbar und Beispielprojekte liegen in Jupyter-Notebooks vor.
Link: [DICHASUS - Tutorials \(uni-stuttgart.de\)](https://www.uni-stuttgart.de/dichasus/tutorials)
- **Online Buch - Netzwerktechnik-Fibel:**
 - Link: [Netzwerktechnik - Elektronik-Kompendium.de](https://www.netzwerktechnik-fibel.de) :
Buch über Funktionsweise von Netzwerktechnik allgemein, insbesondere aber über WiFi.

5 Hürden, Einschränkungen und Next Steps

Auf dieser Seite sollen mögliche Hürden genannt werden, die für den weiteren Verlauf der Entwicklung von Produkten absehbar sind, und wie diese möglicherweise angegangen werden können.

5.1 Zeitliche Verzögerungen zwischen Signal-Eingang und Prädiktion

In Diskussionen über mögliche Use-Cases, in denen die WiFi-motion detection Methoden genutzt werden können, war ein wiederkehrendes Szenario, dass erkannt werden soll, sobald eine Person direkt auf den Receiver (z.B. in einem Kühlschrank verbaut) zuläuft. Besonders in kleineren Räumen (z.B. Küchen) kann der Weg von möglichen Startpunkten, von denen aus diese Bewegung initiiert wird, bis zum Receiver sehr kurz sein. Aber auch in größeren Räumen können Startpunkte nahe am Receiver liegen. Daraus folgt, dass die Bewegung von Interesse nur innerhalb eines sehr kleinen Zeitfensters stattfindet und möglichst frühzeitig erkannt werden sollte, noch bevor die Bewegung tatsächlich abgeschlossen ist (z.B. bevor man am Kühlschrank ankommt). Andernfalls kann eine Reaktion erst zeitversetzt ausgelöst werden.

Das kann z.B. in dem Use-Case der Fall sein, in dem ein Unterdruck im Kühlschrank gelöst werden soll, sobald sich ein Nutzer auf den Kühlschrank zubewegt, damit das Gerät leichter geöffnet werden kann. Diese Reaktion sollte bestenfalls ausgelöst werden, noch bevor der Nutzer am Kühlschrank angekommen ist.

Um in der Lage zu sein, die jeweilige Reaktion auszulösen, müssen in jedem Fall mehrere Schritte für die WiFi-motion detection durchlaufen werden, bei denen verschiedene Faktoren zum Tragen kommen.

- Zuerst muss die Channel State Information (CSI) zu einer (möglichst) fixen Rate immer wieder neu vom Gerät selbst bestimmt werden, bevor sie weiterverwertet werden kann. Da die CSI nicht einfach abgelesen wird, sondern durch Algorithmen geschätzt wird, abhängig von ein- und ausgehenden Signalen, findet in diesem Schritt voraussichtlich schon eine zeitliche Verzögerung von einigen Millisekunden statt. Dieser Faktor ist allerdings sehr schwer zu untersuchen.
- Sobald die gemessene CSI eines Zeitpunkts eingegangen ist, findet ein Preprocessing-Vorgang statt, der die gemessenen Rohdaten so verarbeitet, dass sie im richtigen Format sind, um vom Klassifikations-Algorithmus verarbeitet werden zu können. Abhängig vom geforderten Input-Format des Klassifikations-Algorithmus kann das Preprocessing bereits rechen- und zeitintensive Schritte beinhalten. In unseren Experimenten z.B. war das Preprocessing vergleichsweise rechenintensiv. Die Schritte beinhalteten, dass die Daten zunächst in Abschnitte eines bestimmten Zeit-Intervalls unterteilt wurden, worauf dann Interpolation angewandt wurde. Anschließend wurde die Fast-Fourier-Transformation (FFT) auf die interpolierten Daten angewandt, um deren Output in den Klassifikations-Algorithmus zu speisen. Diese Schritte sind zwar für sich allein genommen effizient umgesetzt, benötigen zusammen aber dennoch eine gewisse Zeit. Klassifikations-Algorithmen, die weniger Preprocessing benötigen und möglicherweise direkt anhand der Rohdaten eine Klassifikation durchführen können, können an dieser Stelle Zeit einsparen.
- Der Klassifikations-Algorithmus selbst benötigt letztendlich ebenfalls Zeit, um aus dem gegebenen Input die Klassifikation zu berechnen. In unseren Experimenten wurde die Entscheidungsbaum-basierte Methode "xgboost" verwendet. Diese Algorithmen liefern in der Inferenz sehr schnell Entscheidungen, da sie nur Bedingungen in den Input-Daten überprüfen müssen, die im Trainings-Prozess vorher bestimmt wurden. Methoden, wie verschiedene neuronale Netze, müssen hingegen viele Rechenoperationen auf den gegebenen Input anwenden, wodurch die Inferenz von diesen verlangsamt wird.

In der zukünftigen Entwicklung ist es also wichtig, zusätzlich zu Bewertungskriterien wie der Accuracy oder der Precision, zu untersuchen, wie die Klassifikation sich in einem Echtzeit-Szenario verhält und wie groß der zeitliche Unterschied zwischen Daten-Eingang und abgeschlossener Klassifikation ist.

5.2 Kurze Dauer der Bewegung von Interesse

In Use-Cases, wie dem oben Beschriebenen, in denen z.B. Bewegungen auf bestimmte Punkte hin rechtzeitig erkannt werden sollen, ist eine weitere Hürde die kurze Dauer dieser Bewegungen. In der Küchen-Versuchsreihe wurde demonstriert, dass die Klasse von Interesse, in der die Bewegung auf den Kühlschrank hin, nur einen sehr kleinen Anteil an der Gesamtdauer der Aufnahmen annahm. Einerseits hat das zur Folge, dass in Trainingsdatensätzen ein starkes Ungleichgewicht der verschiedenen Klassen gibt, die sich schwer zum Nachteil der Klasse von besonderem Interesse auswirkt. Dieses Problem kann zwar teilweise behoben werden, indem man die wenigen Punkte der Klasse von Interesse im Trainings-Prozess höher gewichtet, allerdings erhöht man dadurch gleichzeitig die Gefahr, dass das Klassifikations-Modell zu stark auf die Erkennung dieser wenigen Samples angepasst wird und nicht gut generalisierbar für neue, unbekannte Daten ist.

Deswegen ist es wichtig, dass in Fällen, in denen Bewegungen von solch kurzer Dauer erkannt werden sollen, eine genügend hohe Anzahl an Trainingsdaten erzeugt wird.

5.3 Unidentifizierte Einflussgrößen

Das größte Hindernis, welches einer zuverlässigen Erkennung verschiedener Szenarien entgegensteht, ist, dass sich die CSI-Daten von Zeit zu Zeit unterschiedlich verhielten. Bei gleichen Abläufen, die bei unveränderten Raumbegebenheiten und gleicher Versuchsperson, lediglich zu unterschiedlichen Tagen oder Zeiten ausgeführt wurden, waren oft keine konsistenten Muster zu erkennen. Es bestanden Einflussfaktoren, die sich zu verschiedenen Zeiten, unterschiedlich auf die Daten auswirkten, allerdings nicht identifiziert werden konnten. Außerdem wurde aus den erhobenen Daten ersichtlich, dass bereits kleine Änderungen im Raum, wie das Öffnen eines Fensters, großen Einfluss auf die Daten haben kann. Damit ein Machine Learning Modell lernen kann, zuverlässig zwischen Klassen zu unterscheiden trotz der Anwesenheit vieler Störfaktoren, müssen sich diese Störgrößen zu einem gewissen Grad in den Trainingsdaten wiederfinden. D.h. für einen Trainingsdatensatz, der zu einem zuverlässigen Modell führen kann müssen Daten vorhanden sein, die die Daten der Klassen von Interesse beinhalten, die gleichzeitig die Varianz widerspiegeln, die durch die Störgrößen verursacht werden. Also sollten Daten erhoben werden, die zu unterschiedlichen Zeitpunkten entstehen, für die Objekte verstellt wurden, die in unterschiedlichen Räumen entstehen, usw. Die Daten, die in diesem Projekt gesammelt wurden reichen noch nicht aus, damit ein Machine Learning Modell deren Einfluss von dem der jeweiligen Klassen zuverlässig trennen kann.

5.4 Next Steps

- **Untersuchung auf Bewegung / Anwesenheit on-Axis oder off-Axis:**
 - In der Literatur wird erwähnt, dass die Positionierung relativ zur direkten Verbindungslinie zwischen Transmitter und Receiver eine große Rolle spielt, auf welche Weise die CSI von Objekten oder Personen beeinflusst wird, die sich in einem Raum befinden. Es könnte z.B. mit den Daten aus den Distanz-Versuchen untersucht werden, ob unterschieden werden kann, ob sich eine

Person direkt zwischen Receiver und Transmitter befindet oder nicht. Dadurch könnte die Position einer Person grob eingeschränkt werden, was zur Vorhersage, wohin sich eine Person bewegt, genutzt werden kann.

- **Klassifikation von Betreten und Verlassen des Raums statt bloße “Anwesenheitserkennung”:**

- Unter die Kategorie “eine Person ist anwesend” fallen sehr viele verschiedene Verhaltensmuster. Egal an welchem Ort im Raum sich eine Person aufhält, ob sie sich dort bewegt oder still steht, etc., all diese verschiedenen Muster, die sich jeweils unterschiedlich in der CSI abbilden, würden mit dieser Einteilung dem gleichen Label zugewiesen. Das hat zur Folge, dass ein Klassifikationsalgorithmus, der auf diese Einteilung trainiert wird, lernt, viele verschiedene Muster dieser Klasse zuzuordnen. In Situationen, in denen z.B. eine Person im Nebenraum oder im Flur neben dem beobachteten Raum herumläuft, können so Muster in der CSI entstehen, die denen bei ähnlichen Bewegungen im Raum sehr ähnlich sehen und dadurch mit relativ hoher Wahrscheinlichkeit falsch klassifiziert werden.
Wenn man die Modellierungsfrage ändert und stattdessen versucht, Klassen zu definieren, die nur wenige Verhaltensmuster beinhalten, kann ein Klassifikationsalgorithmus möglicherweise einfacher darauf angepasst werden, diese wenigen Muster zuverlässig korrekt zu erkennen und alle Muster, die von dem bereits Gelernten zu stark abweichen, einer anderen Klasse zuzuordnen.
- Das oben Beschriebene könnte z.B. realisiert werden, indem man eine Methode darauf trainiert zu erkennen, ob eine Person den Raum von Interessen betritt.
- Wenn eine Person den Raum betritt, folgt das meistens einem von wenigen Bewegungsmustern, welche (meistens) lokal an der / den gleichen Stelle(n) stattfinden, da es für gewöhnlich nur begrenzt viele Türen gibt, die in einen Raum führen:
 - Eine Tür öffnen, durch den Türrahmen gehen und die Tür schließen / offenstehen lassen.
 - Durch einen offenen Türrahmen gehen und die Tür schließen / offenstehen lassen.
 - Analog für das Verlassen eines Raums.
- Wenn zuverlässig erkannt wird, wann eine Person einen Raum betritt, bzw. diesen verlässt, kann auch zuverlässig daraus geschlossen werden, dass sich zwischen diesen Abschnitten eine Person im Raum aufhält.
- Ein Ansatz, um diese Überlegungen umzusetzen, ist, ein “Ein-Klassen-Problem” zu formulieren und z.B. durch Methoden wie Autoencoder darauf zu trainieren, das Betreten und Verlassen eines Raums erkennen zu können. Methoden wie diese haben u.A. den Vorteil, dass vergleichsweise wenige Daten für die Trainingsphase gesammelt werden müssen, da im Training nur Daten aus der Klasse, die von Interesse ist, präsentiert werden und daher für einen guten Trainingsdatensatz immer der gleiche Ablauf mit leichten Veränderungen aufgenommen werden kann, ohne darauf achten zu müssen zu viele verschiedene Verhaltensmuster abzudecken.
- In den Daten aus der “Distanzen”-Versuchsreihe wurden bereits in jedem Durchlauf die Abschnitte “Entering room” und “Leaving room” spezifiziert. Diese Daten könnten also dafür verwendet werden, um dieses Szenario zu testen.

- **Untersuchung von MIMO-Geräten:**

- Viele Papers, die sich mit der CSI-Verarbeitung auseinandersetzen, benutzen MIMO-Systeme, also Systeme, in denen nicht nur die Kommunikation zwischen einem Receiver-Transmitter-Paar beobachtet wird, sondern die Kommunikation zwischen Geräten mit mehreren Antennen. Der Unterschied der CSI zwischen

den verschiedenen Antennen-Paaren scheint viel zusätzliche Information mit sich zu bringen im Vergleich zur CSI eines einzelnen Antennen-Paars.

- Selbst wenn absehbar ist, dass in der realen Anwendung später nur einzelne WiFi-Antennen in den hergestellten Geräten verbaut werden können, so ist dennoch davon auszugehen, dass diese mit einem Router verbunden werden, der mehrere Antennen besitzt. Solche Geräte sind mittlerweile eher haushaltsüblich. Daher ist es selbst in diesem Fall sinnvoll, die untersuchten Methoden auf MIMO-Systeme auszuweiten.
- Weiter sollte untersucht werden, wie die eingesetzten Methoden so angepasst werden können, dass sie möglichst dynamisch mit der Anwesenheit unterschiedlich vieler Antennen am jeweiligen Router umgehen können. Ein out-of-the-box Modell sollte funktionieren, egal ob es mit einem Router verbunden ist, der eine, zwei oder drei Antennen besitzt.
- **Untersuchung von alternativen Modellen**
 - Es soll untersucht werden, ob DeepLearning-Methoden noch bessere Ergebnisse liefern können als die bisher verwendeten Methoden.
 - Beispiele dafür sind Transformer- oder Convolutional-Neural Networks.
- **Experimente mit mehreren Personen**
 - Es soll untersucht werden, wie die Vorhersage für bestimmte Szenarien funktioniert, wenn mehrere Personen im Spiel sind. Die Identifikation von Aktionen / Bewegungen von Interesse kann in so einem Szenario noch fordernder sein als mit einzelnen Personen.